

重大 AI 更新提醒

05-27 | 推理速度破纪录、智能体评测基准发布、开源推理框架升级

本期导读

今日 AI 领域迎来多项重大更新：TokenSpeed 引擎在 Qwen3.5-397B-A17B 上实现 580 tps 的推理速度新纪录；IBM 与 Artificial Analysis 联合发布 ITBench-AA 基准，前沿模型在企业 IT 任务上得分不足 50%；llama.cpp 发布 b9370 版本，新增 Hexagon Q4_1 支持，大幅提升移动端推理性能。

已检查来源

GitHub Release、Hugging Face Blog、PyTorch Blog、OpenAI 官方新闻

1. Up to 580tps! New Speed Record of Qwen3.5-397B-A17B on GPU for Agentic Workloads with TokenSpeed

来源 PyTorch Blog | 类型 官方发布 主题 智能体与开发者平台 时间 05-27 10:39 | 分数 7

是什么 TokenSpeed 推理引擎在 GPU 上运行 Qwen3.5-397B-A17B 模型，实现了 580 tokens/秒的推理速度，创下针对智能体工作负载的新纪录。

通俗解释 想象一下，你有一个超级聪明的 AI 助手，但它回答问题很慢，就像打字很慢的人。TokenSpeed 就像给这个助手装上了 闪电打字 能力，让它每秒能输出 580 个单词（token）。这比之前的引擎快很多，尤其适合需要快速响应的场景，比如 AI 自动写代码、实时对话等。它通过消除不必要的内存拷贝、优化计算流程来实现这种速度。

主要作用 解决大模型在智能体场景下推理速度慢的瓶颈，使大规模模型能够实时响应复杂任务，提升用户体验和任务完成效率。

核心功能 系统级消除内存拷贝，减少数据搬运延迟；针对 Qwen3.5-397B-A17B 的 MoE 架构优化，高效利用 GPU 资源；支持智能体工作负载的连续推理，保持高吞吐

对比判断 暂无可信公开对比数据，但 580 tps 是官方宣称的当前最高速度。

适合谁 适合部署大规模语言模型进行实时推理的开发者、AI 应用团队，以及研究推理加速的研究人员。

直达链接 <https://pytorch.org/blog/up-to-580tps-new-speed-record-of-qwen3-5-397b-a17b-on-gpu-for-agentic-workloads-with-tokenspeed/>

2. ITBench-AA: Frontier Models Score Below 50% on the First Benchmark for Agentic Enterprise IT Tasks by Artificial Analysis and IBM

来源 Hugging Face Blog | 类型 官方发布 | 主题 智能体与开发者平台 | 时间 05-27 12:20 | 分数 7

- 是什么** ITBench-AA 是首个专门评估 AI 智能体在企业 IT 任务中表现的基准测试，结果显示当前最先进的前沿模型得分均低于 50%。
- 通俗解释** 想象一下，你让 AI 去完成企业 IT 部门的日常工作，比如排查服务器故障、配置网络、处理工单等。这个新出的 ITBench-AA 基准就像一场 企业 IT 技能考试，考的是 AI 能否像人类 IT 工程师一样解决实际问题。结果发现，即使是最聪明的 AI 模型，得分也不到 50 分（满分 100），说明它们在企业 IT 领域还有很大提升空间。
- 主要作用** 为 AI 智能体在企业 IT 场景中的能力提供标准化评估，帮助开发者了解当前模型的局限性，并推动针对性改进。
- 核心功能** 覆盖故障排查、配置管理、工单处理等典型企业 IT 任务；采用端到端评估，模拟真实工作流；由 IBM 和 Artificial Analysis 联合发布，具有权威性
- 对比判断** 前沿模型得分均低于 50%，具体模型分数未公开，但表明当前模型在企业 IT 任务上远未达到人类水平。
- 适合谁** 适合企业 IT 决策者、AI 智能体开发者、以及关注 AI 落地应用的研究人员。

直达链接 <https://huggingface.co/blog/ibm-research/itbench-aa>

3. ggml-org/llama.cpp release b9370: hexagon: add support for Q41 in MULMAT and MULMATID

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 05-27 13:23 | 分数 8

- 是什么** llama.cpp 发布 b9370 版本，主要新增对 Hexagon DSP 上 Q4_1 量化格式的矩阵乘法支持，并优化了早期唤醒和轮询机制。
- 通俗解释** llama.cpp 是一个让大模型在普通电脑甚至手机上运行的开源工具。这次更新就像给手机里的 AI 引擎换上了 涡轮增压，它让 Hexagon（一种手机芯片里的专用计算单元）能更高效地处理 Q4_1 这种压缩格式的模型。Q4_1 是一种把模型参数压缩到原来 1/4 大小的技术，现在 Hexagon 能直接用它做计算，速度更快、更省电。同时，更新还让 CPU 在等待计算完成时可以提前休息，减少延迟。
- 主要作用** 提升大模型在移动端和边缘设备上的推理性能，通过利用 Hexagon DSP 硬件加速，降低功耗和延迟。
- 核心功能** 新增 Hexagon Q4_1 矩阵乘法支持，覆盖大部分计算图；优化早期唤醒机制，减少纯基准测试的额外延迟；修复 repack 缓冲区溢出问题，提升稳定性
- 对比判断** 暂无可信公开对比数据，但官方声称 Q4_1 支持使 Hexagon 能处理几乎整个计算图，让 CPU 有更多空闲时间。
- 适合谁** 适合在移动设备、嵌入式系统上部署大模型的开发者，以及关注边缘推理优化的研究人员。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9370>

以上信息均来自候选源，请点击链接查看原文。