

重大 AI 更新提醒

05-28 | llama.cpp 修复 CUDA 内核整数溢出问题

本期导读

本期聚焦 llama.cpp 最新版本 b9378，该版本修复了 CUDA 注意力机制内核中的整数溢出 bug，提升了推理稳定性与正确性。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b9378: 修复 CUDA KQ mask 偏移整数溢出

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 05-28 12:03 | 分数 7

是什么 llama.cpp 是一个高性能的 LLM 推理引擎，支持在 CPU 和 GPU 上运行多种大语言模型。本次发布 b9378 版本，主要修复了 CUDA 内核中关于 KQ mask 偏移量的整数溢出问题，该问题会影响注意力机制计算的正确性。

通俗解释 想象你在用计算器做加法，但数字太大导致计算器显示错误结果。llama.cpp 的这次修复就类似解决了这样一个 bug：在 GPU 上计算注意力时，由于偏移量数值过大导致整数溢出，使得模型输出可能出错。修复后，模型在长文本或大 batch 场景下能给出更准确的结果。

主要作用 修复关键性 bug，确保 llama.cpp 在 CUDA 环境下的推理正确性，避免因数值溢出导致的模型输出异常，提升稳定性。

核心功能 修复 CUDA 注意力内核中 KQ mask 偏移量的整数溢出问题；提供 macOS (Apple Silicon/Intel)、iOS、Linux (x64/arm64/s390x) 等多平台二进制包；持续优化跨平台部署体验

对比判断 暂无可信公开对比数据

适合谁 使用 llama.cpp 在 NVIDIA GPU 上进行 LLM 推理的开发者、部署工程师，以及依赖 llama.cpp 构建应用的团队。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9378>

本提醒基于候选源自动生成，请以官方发布为准。