

重大 AI 更新提醒

05-29 | llama.cpp 修复编译器 bug，vLLM 全面强化 DeepSeek V4

本期导读

本期聚焦两个推理框架的重要更新：llama.cpp 因编译器 bug 禁用 CUDA 注意力 PDL 注册，vLLM v0.22.0 则对 DeepSeek V4 做了大量成熟度加固，包括专用包、NVFP4 MoE 支持、MTP 推测解码等。

已检查来源

GitHub Release

1. llama.cpp b9404：因编译器 bug 禁用 CUDA launch_fattn PDL 注册，更新 macOS/iOS 二进制

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 05-29 06:19 | 分数 8

是什么 这是 llama.cpp 项目的一个补丁版本，主要修复了 CUDA 编译器的一个 bug，导致 launch_fattn 的 PDL（持久化数据布局）注册被禁用。同时提供了 macOS Apple Silicon、Intel、iOS 以及 Linux 等平台的二进制包。

通俗解释 想象一下，你有一个非常高效的快递分拣系统（注意力机制），它本来可以自动规划包裹的摆放位置（PDL 注册）来加速分拣。但最近发现快递公司的电脑（编译器）有个 bug，导致这个自动规划功能会出错。于是管理员决定暂时关闭这个自动规划功能，改用更保守的手动方式，确保分拣不会出错。虽然速度可能慢一点点，但至少不会送错包裹。这个版本就是做了这样的安全调整，并重新打包了各个平台的安装文件。

主要作用 解决因编译器 bug 导致的潜在计算错误，保证 llama.cpp 在 CUDA 环境下的稳定性。对于 macOS 和 iOS 用户，提供了最新的二进制文件，方便直接使用。

核心功能 禁用 CUDA launch_fattn 的 PDL 注册，避免编译器 bug 引发错误；提供 macOS Apple Silicon (arm64) 二进制，含 KleidiAI 加速版本（但本次禁用）；提供 macOS Intel (x64)、iOS XCFramework、Linux (x64/arm64/s390x) 二进制

对比判断 暂无可信公开对比数据

适合谁 使用 llama.cpp 在 CUDA GPU 上运行大模型的开发者；需要最新 macOS/iOS 二进制文件的移动端或桌面端应用开发者；关注推理框架稳定性的研究人员。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9404>

2. vLLM v0.22.0 : 459 次提交、230 位贡献者，DeepSeek V4 成熟度大幅提升，Model Runner V2 向默认推进

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 时间 05-29 05:28 | 分数 7

是什么	这是 vLLM 推理框架的一个重要版本更新，包含 459 次提交和 230 位贡献者。核心亮点是对 DeepSeek V4 模型进行了大量加固，包括将其重构为独立包、支持 NVFP4 融合 MoE、CUDA 图、MTP 推测解码等。同时 Model Runner V2 新增了自动选择、权重重载、共享 KV-cache 等功能，逐步向默认运行方式过渡。
通俗解释	想象你有一辆赛车（vLLM），现在要让它更好地驾驭一款新型发动机（DeepSeek V4）。工程师们做了很多工作：把发动机的各个零件整理到专用工具箱（独立包），升级了燃油喷射系统（NVFP4 MoE），优化了点火时序（CUDA 图），还加了一个预测换挡的辅助系统（MTP 推测解码）。同时，赛车的驾驶模式（Model Runner V2）也变得更智能，能自动选择最佳模式，甚至可以在行驶中更换轮胎（权重重载）。这些改进让赛车跑得更快、更稳。
主要作用	大幅提升 vLLM 对 DeepSeek V4 模型的支持成熟度，包括性能、精度和稳定性。同时推进 Model Runner V2 成为默认运行方式，为未来版本奠定基础。
核心功能	DeepSeek V4 重构为独立包 <code>vllm/models/deepseek_v4/</code> ，支持 NVFP4 融合 MoE、CUDA 图、MTP 推测解码；Model Runner V2 新增 <code>oracle</code> 自动选择、 <code>sleep-mode</code> 权重重载、共享 KV-cache 层；大量 fused kernel（MegaMoE、mhc、Q-norm 等）和 ROCm 修复，精度修复
对比判断	暂无可信公开对比数据
适合谁	使用 vLLM 部署 DeepSeek V4 或其他大型语言模型的工程团队；需要高性能推理的 AI 应用开发者；关注推理框架前沿进展的研究人员。

直达链接 <https://github.com/vllm-project/vllm/releases/tag/v0.22.0>

以上更新均来自官方 GitHub Release，建议根据自身环境评估升级。