

重大 AI 更新提醒

05-29 | llama.cpp 修复 CUDA PTX 版本检查，提升 JIT 编译稳定性

本期导读

本期聚焦 llama.cpp 最新 release b9413，该版本修复了 CUDA 后端中 PTX 版本检查不充分导致的 PDL 调度错误，确保在混合 CUDA 架构编译时 JIT 编译的正确性。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b9413: 修复 CUDA PTX 版本检查以正确调度 PDL

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 05-29 13:42 | 分数 7

是什么 这是 llama.cpp 项目的一个 GitHub Release (b9413)，主要修复了 CUDA 后端中 PTX 版本检查逻辑，防止在混合 CUDA 架构编译时出现错误的 PDL (Persistent Data Layout) 调度。

通俗解释 想象你有一台支持多种 CUDA 架构的 GPU (比如 sm_89 和 sm_90a)，编译 llama.cpp 时如果同时指定了这些架构，旧代码可能错误地将为 sm_90a 优化的代码调度到 sm_89 上运行，导致性能下降甚至错误。这个修复通过在运行时检查每个 CUDA 内核的 PTX 版本，确保只有真正兼容的内核才会使用 PDL 优化，就像给每个快递包裹贴上正确的地址标签，避免送错地方。

主要作用 解决在编译时指定多个 CUDA 架构 (如 sm_89 和 sm_90a) 时，JIT 编译可能错误调度 PDL 的问题，提升 llama.cpp 在混合 GPU 环境下的稳定性和性能。

核心功能 运行时检查 cudaFuncAttributes::ptxVersion 来验证内核 PTX 版本；防止在 sm_90/sm_120 等架构上错误使用 PDL 调度；引入 MurmurHash3 混合器改善哈希分布

对比判断 暂无可信公开对比数据

适合谁 使用 llama.cpp 在 NVIDIA GPU 上运行大模型的开发者，特别是那些编译时指定了多个 CUDA 架构 (如 sm_89;90a) 的用户，以及关注推理性能优化的研究人员。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9413>

本简报基于候选源自动生成，请以官方发布为准。