

重大 AI 更新提醒

06-05 | vLLM 与 llama.cpp 发布重要更新

本期导读

本期聚焦推理基础设施的两项关键更新：vLLM v0.22.1 新增 Mellum v2 模型支持并修复多项兼容性问题；llama.cpp b9519 将多列 MMVQ 优化从 CUDA 移植到 SYCL，显著提升 Intel GPU 上的推理性能。

已检查来源

GitHub Release

1. vllm-project/vllm release v0.22.1: 新增 Mellum v2 模型支持与多项修复

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 06-05 05:10 | 分数 8

是什么	vLLM v0.22.1 是一个补丁版本，基于 v0.22.0 修复了多个 bug，并新增了对 JetBrains 的 Mellum v2 模型的支持，以及针对 AMD Zen CPU 的 zentorch 加速量化线性推理。
通俗解释	vLLM 是一个流行的开源推理引擎，用于高效部署大语言模型。这次更新就像给引擎做了一次小保养：修复了几个小毛病，同时增加了一个新零件——支持 JetBrains 新出的 Mellum v2 模型（一个专门写代码的混合专家模型）。另外，如果你用的是 AMD 的 Zen 架构 CPU，现在可以用 zentorch 加速量化后的模型推理，速度更快。
主要作用	解决 v0.22.0 中出现的模型加载、多节点推理等问题，并扩展对新型模型和硬件的支持，让开发者能更稳定地部署最新模型。
核心功能	1. 新增 JetBrains Mellum v2 模型支持，这是一个开源的 MoE 代码生成模型。2. 修复 DeepSeek-V4 初始化时因 CUTLASS fmin 兼容性导致的崩溃。3. 修复 OlmoHybridForCausalLM 因 checkpoint 中 rope_parameters 变化导致的加载失败。4. 修复 HyperCLOVAX 因上游 HuggingFace 仓库移除远程代码而无法加载的问题。
对比判断	暂无可信公开对比数据。
适合谁	使用 vLLM 部署大模型的工程师、研究团队，特别是需要支持 Mellum v2 或 DeepSeek-V4 的用户，以及使用 AMD Zen CPU 进行推理的开发者。

直达链接 <https://github.com/vllm-project/vllm/releases/tag/v0.22.1>

2. ggml-org/llama.cpp release b9519: 将多列 MMVQ 优化从 CUDA 移植到 SYCL

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 06-05 00:45 | 分数 7

是什么	llama.cpp b9519 将 CUDA 后端中的多列矩阵 向量乘法 (MMVQ) 优化移植到 SYCL 后端, 使得 Intel GPU 等 SYCL 设备也能受益于该优化。
通俗解释	llama.cpp 是一个轻量级的 C++ 推理库, 支持多种硬件。这次更新相当于把原本只给 NVIDIA GPU 用的 快速通道 也开放给了 Intel GPU。具体来说, 多列 MMVQ 优化让模型在同时处理多个 token 时, 权重读取次数从每列一次减少到一次, 大幅降低内存带宽压力。比如在生成代码时, 如果一次要预测多个 token, 这个优化能让 Intel GPU 跑得更快。
主要作用	提升 llama.cpp 在 Intel GPU (通过 SYCL 接口) 上的推理性能, 特别是多 token 场景 (如推测解码、多 token 预测), 缩小与 CUDA 后端的性能差距。
核心功能	1. 将多列 MMVQ 优化从 CUDA 移植到 SYCL, 支持 Q4_0、Q8_0、Q3_K、Q4_K、Q5_K、Q6_K 等标准量化类型。2. 修复了 SYCL 后端中权重重排仅在单 token 时触发的 bug, 现在多列场景也能触发重排, 使用更快的 kernel。3. 排除 IQ4_XS 等 IQ 类型, 因其 vec_dot 签名不兼容。
对比判断	暂无可信公开对比数据。
适合谁	使用 Intel GPU (如 Arc 系列) 运行 llama.cpp 的开发者、AI 应用工程师, 以及关注跨平台推理优化的研究人员。
直达链接	https://github.com/ggml-org/llama.cpp/releases/tag/b9519

以上更新均来自官方 GitHub Release, 建议相关用户及时升级以获取最新功能和修复。