

重大 AI 更新提醒

06-08 | NVIDIA 发布 NVFP4 精度训练方案，加速 Blackwell 大模型训练

本期导读

NVIDIA 官方博客宣布，在 JAX 和 MaxText 框架中引入 NVFP4 浮点格式，用于 NVIDIA Blackwell 架构。该技术可显著提升前沿大语言模型的预训练吞吐量，为千卡级训练场景带来性能增益。

已检查来源

NVIDIA Developer Blog

1. Train Models Faster with JAX and MaxText Using NVFP4 on NVIDIA Blackwell

来源 NVIDIA Developer Blog | 类型 官方发布 | 主题 推理性能与基础设施 | 时间 06-08 13:18 | 分数 8

是什么	NVIDIA 官方发布的技术方案，在 JAX 和 MaxText 框架中支持 NVFP4（4位浮点）精度，用于 Blackwell GPU 上的大模型训练。
通俗解释	训练大模型就像盖摩天大楼，每一步都要搬很多砖（数据）。NVFP4 是一种新的 轻量砖块，只有 4位精度，比常用的16位或8位更小，但通过特殊设计保留了关键信息。在 Blackwell GPU 上，使用 NVFP4 可以让每次搬运的砖块更多、速度更快，从而缩短训练时间。例如，训练一个万亿参数模型，原本需要几个月，现在可能节省数周。
主要作用	解决前沿大模型预训练中吞吐量瓶颈问题，通过降低精度计算开销，在不显著牺牲模型质量的前提下提升训练速度，降低训练成本。
核心功能	支持 NVFP4 4位浮点格式，相比 FP8 进一步减少内存和计算量；集成于 JAX 和 MaxText 框架，便于现有工作流迁移；针对 NVIDIA Blackwell 架构优化，利用其硬件特性实现高效计算；保持训练稳定性，通过混合精度策略避免精度损失导致的模型退化
对比判断	暂无可信公开对比数据。博客提到可提升 step 吞吐量，但未给出具体数值。
适合谁	适合使用 JAX 或 MaxText 训练大语言模型的研究团队、AI 基础设施工程师、以及希望降低训练成本的 AI 公司。

直达链接 <https://developer.nvidia.com/blog/train-models-faster-with-jax-and-maxtext-using-nvfp4-on-nvidia-blackwell/>

本简报基于候选源自动生成，请以官方信息为准。