

重大 AI 更新提醒

06-10 | Transformers v5.11.0 发布、Helion 集成 vLLM 提升推理性能

本期导读

本期重点关注 Hugging Face Transformers 库 v5.11.0 版本，新增 DiffusionGemma 和 DeepSeek-V3.2 模型支持；同时 PyTorch 博客介绍了 Helion 内核集成到 vLLM 中，实现 FP8 推理加速。

已检查来源

GitHub Release、PyTorch Blog

1. huggingface/transformers v5.11.0 发布：新增 DiffusionGemma 与 DeepSeek-V3.2 模型

来源 GitHub Release | 类型 GitHub Release | 主题 检索增强与向量模型 时间 06-10 11:32 | 分数 8

是什么	Hugging Face Transformers 库发布 v5.11.0 版本，主要新增了 DiffusionGemma 和 DeepSeek-V3.2 两个模型的支持。DiffusionGemma 是一种采用编码器-解码器架构的模型，专为推理速度优化，通过多画布采样（multi-canvas sampling）实现块自回归生成，而非逐 token 生成。DeepSeek-V3.2-Exp 是 DeepSeek-AI 的实验性模型，引入了 DeepSeek Sparse Attention 机制。
通俗解释	想象一下，传统的语言模型生成文本就像一个人一个字一个字地说话，速度很慢。而 DiffusionGemma 就像一个人同时想好一整句话，然后一口气说出来，速度自然快很多。它使用一种叫做 扩散采样器 的技术，先产生一个模糊的句子块，然后逐步去噪，最终得到清晰的文本。DeepSeek-V3.2-Exp 则是一种新的注意力机制，可以让模型在处理长文本时更高效，只关注重要的部分，而不是所有内容。
主要作用	该版本让开发者能够更方便地使用最新的高效模型进行文本生成任务，特别是 DiffusionGemma 在推理速度上的提升，对于需要实时响应的应用（如聊天机器人、实时翻译）非常有价值。DeepSeek-V3.2-Exp 则适合处理长文档或需要高效注意力机制的场景。
核心功能	DiffusionGemma 采用块自回归生成，通过多画布采样一次性生成多个 token，显著提升推理速度。；DeepSeek-V3.2-Exp 引入 DeepSeek Sparse Attention，减少计算量，适合长序列处理。；Transformers 库提供完整的文档和集成，方便开发者直接调用。
对比判断	暂无可信公开对比数据。
适合谁	适合使用 Transformers 库进行文本生成任务的 AI 开发者、研究人员，以及需要高效推理的工程团队。
直达链接	https://github.com/huggingface/transformers/releases/tag/v5.11.0

2. Portable vLLM Model Inference Kernels in Helion

来源 PyTorch Blog | 类型 官方发布 主题 推理性能与基础设施 时间 06-10 12:00 | 分数 7

是什么	PyTorch 博客发布文章介绍 Helion 内核集成到 vLLM 中，用于 FP8 推理。Helion 提供 PyTorch 原生的可移植内核，在 NVIDIA H100 和 B200 GPU 上使用 Qwen3 模型进行了评估。
通俗解释	Helion 就像一套高效的积木块，专门用来搭建 AI 模型推理的引擎。vLLM 是一个流行的推理框架，现在 Helion 的积木块被集成到 vLLM 中，让 vLLM 能够更高效地运行 FP8（8 位浮点数）推理。FP8 是一种节省内存和计算资源的数据格式，但需要专门的优化才能发挥性能。Helion 内核让这些优化变得简单且可移植，开发者不需要为不同 GPU 写不同的代码。
主要作用	解决 vLLM 在 FP8 推理时内核性能不足和可移植性差的问题，使开发者能够轻松地在不同 GPU 上获得高性能推理。
核心功能	Helion 内核是 PyTorch 原生的，易于集成和使用。；支持 FP8 推理，减少内存占用并提升吞吐量。；在 NVIDIA H100 和 B200 GPU 上经过验证，具有可移植性。
对比判断	暂无可信公开对比数据。
适合谁	适合使用 vLLM 进行模型推理的工程师、研究高性能推理的开发者，以及需要跨 GPU 平台部署的团队。
直达链接	https://pytorch.org/blog/portable-vllm-model-inference-kernels-in-helion/

以上信息基于候选源整理，请以官方发布为准。