

重大 AI 更新提醒

06-21 | llama.cpp 发布 b9745，支持多 token 推测解码加速

本期导读

本期聚焦 llama.cpp 最新 release b9745，该版本引入了对 Step3.5/3.7 flash MTP3 的支持，通过多 token 推测解码（Multi-Token Prediction）显著提升推理速度，并新增了相关 API 接口。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b9745: 支持 Step3.5/3.7 flash MTP3 多 token 推测解码

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 06-21 06:38 | 分数 7

是什么 这是 llama.cpp 项目的一个 GitHub Release 版本 b9745，主要更新是实现了多 token 推测解码（Multi-Token Prediction, MTP）的支持，具体包括 Step3.5 和 Step3.7 的 flash MTP3 功能。该版本新增了 mtp_layer_offset 参数，并在图复用中包含 nextn 标志，同时添加了 llama_set_mtp_layer_offset 和 llama_model_n_nextn_layer 两个 API。

通俗解释 推测解码是一种加速大模型推理的技术，就像猜谜时一次猜多个答案而不是一个一个猜。传统模型每次只生成一个 token（比如一个字），而 MTP 允许模型一次预测多个 token，然后并行验证，从而减少推理步骤。例如，在生成一段文字时，模型可以同时预测接下来的 3 个词，然后一次性检查它们是否正确，这样速度就能提升好几倍。这个版本让 llama.cpp 支持了更高效的 MTP 实现，特别是针对某些模型架构的优化。

主要作用 主要目的是提升 llama.cpp 在本地运行大模型时的推理速度，尤其是对于需要快速生成大量文本的场景，如聊天机器人、代码补全等。通过多 token 推测解码，用户可以在相同硬件上获得更快的响应速度。

核心功能 支持 Step3.5/3.7 flash MTP3 多 token 推测解码；新增 mtp_layer_offset 参数，允许灵活配置 MTP 层偏移；新增 llama_set_mtp_layer_offset 和 llama_model_n_nextn_layer API，方便开发者集成；优化图复用逻辑，包含 nextn 标志，提升计算效率

对比判断 暂无可信公开对比数据

适合谁 适合使用 llama.cpp 在本地部署大模型的开发者、AI 应用开发者以及需要低延迟推理的研究人员。特别是那些希望在不升级硬件的情况下提升模型生成速度的用户。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9745>

以上信息基于候选源，请以官方发布为准。