

重大 AI 更新提醒

06-22 | llama.cpp 新增工具调用响应 ID，强化智能体开发

本期导读

本期聚焦 llama.cpp 最新版本 b9763，该版本为工具调用 API 添加了响应 ID 支持，提升了多轮工具交互的可靠性。对于在本地或移动端构建 AI 智能体的开发者而言，这是一个重要的基础设施更新。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b9763: server : Add id to tool call responses api

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 06-22 16:32 | 分数 7

是什么 这是 llama.cpp 项目的一个新版本发布（b9763），主要更新是在其 HTTP 服务器的工具调用（tool call）响应 API 中增加了唯一标识符（id）字段。llama.cpp 是一个高性能的 C/C++ 推理引擎，支持在 CPU、GPU 和移动设备上运行大型语言模型。

通俗解释 想象一下你让一个 AI 助手同时做两件事：查天气和订餐厅。以前，AI 返回的两个工具调用结果可能没有明确的标签，你很难区分哪个结果对应哪个请求。现在，每个工具调用响应都带有一个唯一的 ID，就像快递单号一样，你可以精确地把每个结果和对应的请求匹配起来。这对于构建能连续调用多个工具的智能体（比如自动规划行程的助手）非常重要。

主要作用 解决多工具调用场景下的响应匹配问题，使开发者能够更可靠地处理并发或顺序的工具调用，提升智能体系统的稳定性和可调试性。

核心功能 为每个工具调用响应添加唯一 id 字段，便于追踪和关联；兼容 OpenAI 风格的 tool call API，降低迁移成本；支持 macOS（Apple Silicon 和 Intel）、iOS、Linux 等多种平台；提供预编译二进制和 XCFramework，方便集成

对比判断 暂无可信公开对比数据

适合谁 适合在本地或边缘设备上部署 LLM 的开发者、研究智能体系统的团队、以及需要构建自定义工具调用流程的 AI 应用开发者。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9763>

以上信息基于候选源，请以官方发布为准。