

重大 AI 更新提醒

06-23 | llama.cpp 发布 b9767, WebGPU 小批量推理性能提升

本期导读

本期聚焦 llama.cpp 最新版本 b9767, 该版本针对 WebGPU 后端优化了小批量解码时的矩阵 向量乘法路径, 显著提升了 MTP (Multi-Token Prediction) 推理速度。对于在浏览器或移动端运行大模型的开发者来说, 这是一个重要的性能改进。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b9767: 优化 WebGPU 小批量 MTP 推理

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 06-23 03:58 | 分数 7

是什么 这是 llama.cpp 项目的一个新版本 (b9767), 主要改进了 WebGPU 后端在处理小批量数据时的推理性能。具体来说, 它通过使用矩阵 向量乘法路径来加速小批量的解码过程, 并添加了必要的同步屏障 (barrier) 来保证正确性。

通俗解释 想象一下, 你有一个非常聪明的 AI 助手, 但它每次回答问题都需要思考很久。如果一次只问一个问题 (小批量), 它反而会花更多时间在准备上, 而不是真正回答问题。这个更新就像是给 AI 助手换了一个更高效的思考方式: 当问题很少时, 它不再用复杂的矩阵乘法 (像做一大桌菜), 而是用更简单的向量乘法 (像做一道小菜), 从而更快地给出答案。对于在浏览器或手机上运行 AI 模型的用户来说, 这意味着更快的响应速度。

主要作用 解决 WebGPU 后端在小批量推理场景下的性能瓶颈, 使得在浏览器或支持 WebGPU 的设备上运行大语言模型时, 多 token 预测 (MTP) 能够更快地生成结果, 提升用户体验。

核心功能 针对小批量解码使用矩阵 向量乘法路径, 减少计算冗余; 添加 barrier 同步机制, 确保多线程并行计算的正确性; 仅影响 WebGPU 后端, 不影响 CPU 或 CUDA 等其他后端

对比判断 暂无可信公开对比数据

适合谁 适合在浏览器或移动端部署大语言模型的开发者, 尤其是使用 WebGPU 进行推理的团队; 也适合对 llama.cpp 推理性能优化感兴趣的研究人员。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9767>

本简报基于候选源生成, 请以官方发布为准。