

重大 AI 更新提醒

06-23 | NVIDIA Blackwell 推理加速 llama.cpp Vulkan 增强

本期导读

本期聚焦两项重要更新：NVIDIA 发布 DFlash 投机解码技术，在 Blackwell GPU 上实现最高 15 倍推理加速；llama.cpp 新版本 b9774 大幅增强 Vulkan 后端，支持更多数学运算和测试。

已检查来源

NVIDIA Developer Blog、GitHub Release

1. Boost Inference Performance up to 15x on NVIDIA Blackwell Using DFlash Speculative Decoding

来源 NVIDIA Developer Blog | 类型 官方发布 主题 智能体与开发者平台 时间 06-23 10:00 | 分数 8

是什么 NVIDIA 官方博客发布的一项新技术 DFlash Speculative Decoding，旨在利用投机解码（Speculative Decoding）方法，在最新的 Blackwell GPU 上大幅提升大语言模型的推理性能，最高可达 15 倍。

通俗解释 想象一下，你写文章时，先快速写一个草稿，再慢慢修改。投机解码就像这样：让一个小模型快速生成多个可能的下一段文字（草稿），然后大模型一次性检查这些草稿是否正确。如果草稿大部分正确，就能省去大模型逐字生成的时间。DFlash 是 NVIDIA 针对 Blackwell GPU 优化过的投机解码方案，它利用硬件特性让这个过程更快，就像给草稿检查配上了高速扫描仪。

主要作用 解决多智能体协作等场景下对低延迟推理的迫切需求。随着 AI 系统从单轮对话转向多智能体工作流，推理速度成为瓶颈。DFlash 通过减少每次生成所需的计算量，显著降低延迟，使实时交互成为可能。

核心功能 基于投机解码的推理加速，最高 15 倍性能提升；针对 NVIDIA Blackwell GPU 架构深度优化；支持多智能体工作流等低延迟场景；兼容现有 LLM 模型，无需重新训练

对比判断 暂无可信公开对比数据。博客声称相比标准自回归解码，在 Blackwell GPU 上可实现最高 15 倍加速，但未提供与其他投机解码方案的直接对比。

适合谁 适合使用 NVIDIA Blackwell GPU 进行 LLM 推理的开发者、AI 系统架构师，以及构建多智能体应用或需要低延迟响应的团队。

直达链接 <https://developer.nvidia.com/blog/boost-inference-performance-up-to-15x-on-nvidia-blackwell-using-dflash-speculative-decoding/>

2. ggml-org/llama.cpp release b9774: vulkan: support all backend tests for SQR/SQRT/SIN/COS/CLAMP/LEAKYRELU/NORM

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 06-23 11:17 | 分数 7

是什么	llama.cpp 项目发布版本 b9774，主要更新是完善了 Vulkan 后端的支持，使其能够通过所有后端测试，包括 SQR、SQRT、SIN、COS、CLAMP、LEAKY_RELU、NORM 等数学运算，并修复了非连续张量处理等问题。
通俗解释	llama.cpp 是一个让你在普通电脑上运行大语言模型的工具，它支持多种计算后端（如 CPU、CUDA、Vulkan）。Vulkan 是一种跨平台的图形和计算 API，常用于游戏，但也能加速 AI 计算。这次更新就像给 Vulkan 后端打了一个补丁，让它能正确执行更多数学操作（比如平方根、正弦、余弦等），并且能处理形状不规则的张量。这意味着使用 AMD 显卡或集成显卡的用户，在运行模型时能获得更好的兼容性和性能。
主要作用	提升 llama.cpp 在 Vulkan 后端上的稳定性和功能完整性，使更多用户（尤其是非 NVIDIA 显卡用户）能够高效运行 LLM。同时修复了 CPU 后端和 CUDA 后端的一些问题，确保跨平台一致性。
核心功能	Vulkan 后端新增对 SQR、SQRT、SIN、COS、CLAMP、LEAKY_RELU、NORM 等运算的支持；修复非连续张量在 NORM 和 L2_NORM 中的处理；更新 CPU 后端以正确处理非连续行测试用例；提供 macOS、iOS、Linux 等多平台预编译二进制文件
对比判断	暂无可信公开对比数据。本次更新未提供性能对比，主要聚焦功能完整性和正确性。
适合谁	适合使用 llama.cpp 在非 NVIDIA GPU（如 AMD、Intel、Apple Silicon）上运行 LLM 的开发者和爱好者，以及需要跨平台推理支持的研究人员。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9774>

以上信息基于候选源整理，请以官方发布为准。