

重大 AI 更新提醒

06-25 | llama.cpp 新增 SYCL 张量并行支持

本期导读

本期聚焦 llama.cpp 最新 release b9788，该版本为 SYCL 后端引入了张量并行（`split-mode tensor`）功能，支持双 GPU 场景下的高效 all-reduce，显著提升推理性能。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b9788: SYCL 张量并行支持双 GPU

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 06-25 03:45 | 分数 7

是什么 这是 llama.cpp 的一个 GitHub Release（b9788），主要新增了 SYCL 后端对张量并行（`tensor parallelism`）的支持，允许在双 GPU 配置下通过 `split-mode tensor` 参数实现模型推理的分布式加速。

通俗解释 想象一下，你有一个很大的 AI 模型，单个 GPU 放不下或者跑得太慢。张量并行就像把一个大蛋糕切成几块，分给多个 GPU 同时处理，最后再把结果拼起来。这个更新让使用 Intel 或 AMD GPU（通过 SYCL 编程模型）的用户也能享受这种加速。具体来说，它实现了两种 all-reduce 路径：对于小张量（元素数 ≤ 32768 ），采用 BF16 压缩，将 FP32 数据压缩为 BF16 后传输，PCIe 带宽减半；对于大张量，则使用 FP32 直接传输。这类似于 CUDA 后端已有的 NCCL all-reduce 模式。

主要作用 解决 SYCL 后端缺乏张量并行支持的问题，使得在双 GPU 系统上运行大型语言模型时，能够通过模型分片降低单卡显存压力并提升推理吞吐量。对于使用 Intel 或 AMD GPU 的开发者来说，这是一个重要的性能优化。

核心功能 支持 `split-mode tensor` 参数，启用张量并行；实现 `comm_init/comm_free/comm_allreduce_tensors` 三件套，供元后端通过 `get_proc_address` 调用；针对双 GPU 场景实现退化环 all-reduce，包含小张量 BF16 压缩路径和大张量 FP32 路径；小张量路径将 PCIe 字节减半，适合通信密集型操作

对比判断 暂无可信公开对比数据。该实现模式与 CUDA 后端的 NCCL all-reduce 类似，但具体性能数据未在发布说明中提供。

适合谁 适合使用 Intel 或 AMD GPU（支持 SYCL）的 AI 推理开发者、llama.cpp 用户、以及需要双 GPU 部署大模型的团队。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9788>

本简报基于候选源自动生成，请以官方发布为准。