

重大 AI 更新提醒

06-29 | Ray 2.56.0 发布：数据稳定性与 LLM 服务性能大幅提升

本期导读

Ray 2.56.0 正式发布，重点改进了 Ray Data 的稳定性，并重构了 Ray Serve LLM 的请求处理架构，显著提升了 LLM 推理性能。新版本还引入了会话粘性路由等新策略，适合大规模分布式训练和模型服务场景。

已检查来源

GitHub Release

1. Ray 2.56.0 发布：数据稳定性增强与 LLM 服务性能优化

来源 GitHub Release | 类型 GitHub Release | 主题 检索增强与向量模型 时间 06-29 15:32 | 分数 7

是什么 Ray 2.56.0 是分布式计算框架 Ray 的最新版本，主要包含 Ray Data 模块的稳定性改进和 Ray Serve LLM 的架构重构。Ray Data 新增了许多数据集集群运行、CPU map-batches 自动批量大小选择、默认逻辑内存配置以防止 OOM，并减少了对对象存储溢出。Ray Serve LLM 通过解耦请求处理与 token 流式响应路径，显著提升了 LLM 服务性能，同时引入了 ConsistentHashRouter 和 CapacityQueueRouter 等新路由策略。

通俗解释 Ray 是一个帮助开发者轻松运行分布式计算（比如训练大型 AI 模型或提供模型服务）的框架。这次更新主要做了两件事：第一，让数据处理更稳定 比如你同时处理多个数据集时不会崩溃，系统会自动选择合适的数据批量大小，避免内存溢出；第二，让 AI 模型服务更快 以前处理用户请求和生成回答是混在一起的，现在分开了，就像餐厅里点菜和做菜分开，效率更高。另外还增加了新功能，比如可以根据用户会话保持路由到同一台机器，适合聊天机器人等场景。

主要作用 解决大规模分布式训练和模型服务中的稳定性与性能瓶颈，特别是 LLM 推理场景下的高吞吐和低延迟需求。

核心功能 Ray Data 稳定性增强：支持多数据集集群运行，自动批量大小选择，默认逻辑内存配置防止 OOM，减少对象存储溢出。；Ray Serve LLM 架构重构：解耦请求处理与 token 流式响应路径，提升 LLM 服务性能。；新路由策略：ConsistentHashRouter 实现会话粘性路由，CapacityQueueRouter 优化队列管理。

对比判断 暂无可信公开对比数据

适合谁 适合使用 Ray 进行分布式训练、数据处理和模型服务的 AI 工程师、数据科学家和 MLOps 团队，特别是需要部署 LLM 服务的开发者。

直达链接 <https://github.com/ray-project/ray/releases/tag/ray-2.56.0>

本简报基于候选源生成，请以官方发布为准。