

重大 AI 更新提醒

07-01 | llama.cpp 发布 b9856，CUDA 推理性能再提升

本期导读

本期聚焦 llama.cpp 最新版本 b9856，该版本在 CUDA 后端引入了 `restrict__` 关键字和 PDL 优化，显著提升了 Flash Attention 的计算效率。同时提供了 macOS、iOS、Linux 等多平台二进制包，方便开发者快速部署。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b9856: CUDA: consistent use of restrict + PDL for FA (25185) macOS/iOS

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 07-01 06:09 | 分数 7

是什么 llama.cpp 是一个高性能的 LLM 推理引擎，支持在 CPU 和 GPU 上运行多种大语言模型。本次 b9856 版本主要针对 CUDA 后端进行了优化，统一使用了 `restrict__` 关键字并引入了 PDL (Parallel Data Layout) 技术来加速 Flash Attention 计算。

通俗解释 想象一下，大模型在推理时需要处理大量数据，就像快递员要分拣成千上万的包裹。Flash Attention 是一种高效的注意力机制，能让模型更快地处理长文本。这次更新相当于给快递员配备了更清晰的标签 (`restrict__`) 和更合理的货架布局 (PDL)，让分拣速度大幅提升。对于普通用户来说，这意味着在支持 CUDA 的显卡上运行 Llama 等模型时，响应速度会更快，尤其是在处理长对话或长文档时效果更明显。

主要作用 提升 llama.cpp 在 NVIDIA GPU 上的推理性能，特别是 Flash Attention 的计算效率，从而降低延迟，改善用户体验。

核心功能 CUDA 后端统一使用 `restrict__` 关键字，减少内存别名冲突，提高编译器优化效果；引入 PDL (Parallel Data Layout) 优化 Flash Attention 的数据布局，提升并行计算效率；提供 macOS (Apple Silicon 和 Intel)、iOS、Linux (x64、arm64、s390x) 等多平台预编译二进制包，方便快速部署

对比判断 暂无可信公开对比数据

适合谁 适合使用 NVIDIA GPU 进行本地 LLM 推理的开发者、AI 应用部署工程师，以及希望在 macOS/iOS 设备上运行大模型的用户。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9856>

以上信息基于候选源，请以官方发布为准。