

重大 AI 更新提醒

07-05 | Hugging Face Transformers 新增 Kimi K2.5 系列；llama.cpp 优化 MoE 推理

本期导读

本期带来两项重要更新：Hugging Face Transformers v5.13.0 正式支持开源多模态智能体模型 Kimi K2.5 系列；llama.cpp 通过 CUDA 内核优化，使 288 专家 MoE 模型推理速度显著提升。

已检查来源

GitHub Release

1. huggingface/transformers v5.13.0 发布：新增 Kimi K2.5、K2.6、K2.7 模型架构

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 07-03 11:06 | 分数 8

是什么 Hugging Face Transformers 库发布 v5.13.0 版本，主要新增了 Kimi K2.5、K2.6 和 K2.7 系列模型的架构支持。Kimi K2.5 是一个开源的原生多模态智能体模型，具备长周期编码、编码驱动设计、主动自主执行和群体任务编排等能力。

通俗解释 想象你有一个 AI 助手，它不仅能看懂文字和图片，还能主动帮你写代码、设计网页，甚至协调多个 AI 一起完成复杂任务。Kimi K2.5 就是这样一个模型，它开源且免费可用。现在通过 Hugging Face Transformers 库，开发者可以轻松调用它，就像使用其他流行模型一样简单。例如，你给它一张手绘草图，它就能生成一个可运行的网页界面。

主要作用 为开发者提供最新开源多模态智能体模型的官方支持，降低集成门槛，推动智能体应用开发。

核心功能 原生多模态：同时处理文本和视觉输入，实现图文理解与生成。；智能体能力：支持长周期编码任务、自主执行和群体协作（swarm orchestration）。；跨语言泛化：在 Rust、Go、Python 等多种编程语言上表现稳健。；生产级输出：能将简单提示和视觉输入转化为可直接部署的界面。

对比判断 暂无可信公开对比数据。

适合谁 适合 AI 应用开发者、智能体研究者、需要多模态能力的团队，以及希望基于开源模型构建自动化工作流的开发者。

直达链接 <https://github.com/huggingface/transformers/releases/tag/v5.13.0>

2. llama.cpp b9866 : CUDA 启用 288 专家 TopK-MoE 融合，推理速度提升

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 07-03 09:20 | 分数 7

是什么	llama.cpp 发布 b9866 版本，针对 CUDA 后端优化了 TopK-MoE（混合专家）融合内核，使其支持 288 个专家的模型（如 Step-3.7-Flash）。此前仅支持 2 的幂次专家数或特殊值 576，288 专家模型会回退到未融合的逐层路由链，增加额外计算开销。
通俗解释	混合专家模型（MoE）就像把多个小型专家模型组合成一个超级模型，每次只激活部分专家。但专家数量不是 2 的幂次时，计算效率会下降。这次更新让 llama.cpp 在 CUDA 显卡上能高效处理 288 个专家的模型，避免了额外的计算步骤。实测在 AMD gfx1151 显卡上，生成速度（tg128）从 20.71 tokens/秒提升到 24.21 tokens/秒，提升约 17%。
主要作用	提升非标准专家数 MoE 模型在消费级显卡上的推理效率，让更多模型能流畅运行。
核心功能	支持 288 专家数：填补了非 2 的幂次专家数的性能缺口。；CUDA 内核融合：将多个路由操作合并，减少图节点数量（每 token 减少约 330 个节点）。；兼容现有硬件：在 AMD gfx1151 上验证有效，预计 NVIDIA GPU 同样受益。
对比判断	在 AMD gfx1151 上，Step-3.7-Flash IQ4_XS 模型生成速度从 20.71 0.13 tokens/秒提升至 24.21 0.10 tokens/秒，提升约 17%；预填充速度基本不变。
适合谁	适合在本地或边缘设备上运行 MoE 模型的开发者、推理优化工程师，以及使用非标准专家数模型的用户。
直达链接	https://github.com/ggml-org/llama.cpp/releases/tag/b9866

以上信息基于候选源，请以官方发布为准。