

重大 AI 更新提醒

07-06 | llama.cpp 发布 b9890，重构 CUDA 后端提升推理性能

本期导读

本期聚焦 llama.cpp 最新版本 b9890，该版本对 CUDA 后端进行了重大重构，移除 sm row 并重构 cuBLAS 集成，修复了 CDNA + BF16 逻辑等问题，旨在提升 NVIDIA GPU 上的推理效率与兼容性。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b9890: CUDA: remove -sm row, refactor cuBLAS

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 07-06 15:45 | 分数 7

是什么 llama.cpp 是一个用于在本地设备上高效运行大型语言模型（如 LLaMA）的开源推理引擎，支持 CPU、GPU 等多种后端。本次发布的 b9890 版本主要针对 CUDA（NVIDIA GPU 计算平台）后端进行了重构，移除了 sm row 参数并重构了 cuBLAS（NVIDIA 的线性代数库）集成，同时修复了 CDNA（AMD GPU 架构）与 BF16 数据类型的逻辑错误。

通俗解释 想象一下，你有一个超级聪明的 AI 助手（大语言模型），但运行它需要强大的计算能力。llama.cpp 就像一个高效的 翻译官，让这个 AI 能在你的个人电脑或手机上运行。这次更新相当于给 翻译官 换了一个更聪明的大脑 来处理 NVIDIA 显卡上的计算任务。具体来说，它移除了一个旧的优化参数（sm row），重新设计与 cuBLAS 的协作方式，并修复了在 AMD 显卡上使用 BF16（一种节省内存的数据格式）时可能出现的 bug。这样，无论你用的是 NVIDIA 还是 AMD 的显卡，AI 都能更稳定、更快速地运行。

主要作用 提升 llama.cpp 在 NVIDIA GPU 上的推理性能和稳定性，同时修复 AMD GPU 上的兼容性问题，使更多用户能在本地高效运行大语言模型。

核心功能 移除 sm row 参数，简化 CUDA 后端配置；重构 cuBLAS 集成，优化矩阵运算效率；修复 CDNA（AMD GPU）与 BF16 数据类型的逻辑错误；修复 src0 步长和连续性问题，确保数据正确性

对比判断 暂无可信公开对比数据

适合谁 适合需要在本地部署大语言模型的开发者、AI 研究人员以及希望利用 GPU 加速推理的团队。尤其适合使用 NVIDIA 或 AMD 显卡的用户。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9890>

本简报基于候选源自动生成，请以官方发布为准。