

重大 AI 更新提醒

07-07 | NVIDIA Vera CPU 提升 AI 工厂吞吐量，加速智能体工作负载

本期导读

本期聚焦 NVIDIA 最新 Vera CPU 如何通过架构创新提升 AI 工厂吞吐量，特别针对智能体工作负载进行优化，为开发者提供 stronger 推理与编排能力。

已检查来源

NVIDIA Developer Blog

1. NVIDIA Vera CPU Boosts AI Factory Throughput to Accelerate Agentic Workloads

来源 NVIDIA Developer Blog | 类型 官方发布 主题 智能体与开发者平台 时间 07-07 10:10 | 分数 8

是什么 NVIDIA 官方发布的 Vera CPU 技术介绍，该 CPU 专为 AI 工厂设计，通过提升吞吐量来加速智能体工作负载。智能体系统将模型推理转化为行动，涉及多步骤工作流，包括推理、工具使用、代码执行、检索、编排等。

通俗解释 想象一个 AI 助手需要帮你完成复杂任务，比如预订旅行：它需要理解你的需求、搜索航班、比较价格、调用支付接口、确认订单。每一步都可能调用不同的模型或工具。NVIDIA Vera CPU 就像给这个助手装上了更快的引擎，让它在处理这些多步骤任务时速度更快、效率更高。具体来说，Vera CPU 优化了推理、工具调用、代码执行等环节的协同，使得整个工作流能更顺畅地运行。

主要作用 解决智能体系统在多步骤推理和工具调用场景下的性能瓶颈，提升 AI 工厂的整体吞吐量，使开发者能够构建更复杂、更高效的智能体应用。

核心功能 针对多步骤工作流优化：支持推理、工具使用、代码执行、检索、编排等环节的流水线加速。；高吞吐量架构：通过 CPU 与 GPU 的协同设计，减少数据搬运延迟，提升整体处理能力。；智能体专用加速：内置对 agentic 工作负载的硬件级支持，如快速上下文切换和任务调度。

对比判断 暂无可信公开对比数据

适合谁 适合 AI 工厂运维人员、智能体应用开发者、大模型推理优化工程师，以及需要构建复杂多步骤 AI 工作流的团队。

直达链接 <https://developer.nvidia.com/blog/nvidia-vera-cpu-boosts-ai-factory-throughput-to-accelerate-agentic-workloads/>

本简报基于 NVIDIA 官方博客信息，仅供参考。