

重大 AI 更新提醒

07-08 | llama.cpp 发布 CUDA NVFP4 融合优化，推理速度提升

本期导读

本期聚焦 llama.cpp 最新版本 b9911，该版本针对 NVIDIA GPU 上的 NVFP4 数据类型进行了 CUDA 内核融合优化，显著提升了模型推理速度，尤其对 MoE 架构模型效果明显。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b9911: CUDA 融合 MMVQ 后缩放与 NVFP4 推理优化

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 时间 07-08 01:58 | 分数 7

是什么 这是 llama.cpp 项目的一个正式发布版本（b9911），主要针对 NVIDIA GPU 上的 NVFP4（NVIDIA 4-bit 浮点）数据类型，通过融合矩阵 向量量化（MMVQ）操作中的后缩放步骤，减少显存访问和计算开销，从而加速推理。

通俗解释 想象一下，你在做一道复杂的数学题，需要先算乘法再算加法。如果每次算完乘法都把结果存到黑板上，再擦掉重新写加法，就会很慢。这个更新相当于把乘法和加法合并成一步，直接在脑子里算完，省去了写黑板的时间。具体到 AI 推理，NVFP4 是一种用 4 位浮点数表示模型权重的方法，可以大幅减少模型占用的显存，但计算时需要额外的缩放操作。这次更新把缩放操作融合到矩阵乘法中，让 GPU 一次完成更多工作，从而提升速度。例如，在 Qwen2.5-MoE 35B 模型上，推理速度提升了约 4%。

主要作用 主要目的是提升 llama.cpp 在 NVIDIA GPU 上运行 NVFP4 量化模型的推理性能，让开发者能够以更低的延迟运行大模型，尤其适合需要高吞吐量的应用场景。

核心功能 CUDA 内核融合：将 MMVQ 的后缩放步骤与矩阵乘法融合，减少显存读写次数。；支持 NVFP4 数据类型：针对 NVIDIA 4-bit 浮点格式进行专门优化。；批量大小为 1 的优化：特别优化了单次推理场景（BS=1），适合交互式应用。；自动测试验证：通过 test-backend-ops 确保正确性，并手动验证了模型精度。

对比判断 在 B4500 GPU 上测试 Qwen2.5-MoE 35B 模型（NVFP4 量化），文本生成速度从 150.15 tokens/s 提升至 156.29 tokens/s，加速约 4%；而 Q4_K_M 量化版本速度基本不变（157.91 vs 157.64 tokens/s）。在 DGX Spark 上也有类似提升。暂无可信公开对比数据与其他推理框架。

适合谁 适合使用 llama.cpp 在 NVIDIA GPU 上部署大语言模型的开发者、研究人员，尤其是需要低延迟推理的聊天机器人、实时助手等应用。对 MoE（混合专家）模型用户尤其有益。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9911>

本简报基于候选源生成，请以官方发布为准。