

重大 AI 更新提醒

07-08 | PyTorch 2.13.0 发布、llama.cpp 更新、NVIDIA 加速 Presto 与智能体

本期导读

本期带来 PyTorch 2.13.0 正式版，重点提升 Apple Silicon 上的 FlexAttention 性能并引入新通信后端；llama.cpp 新增 CUDA f16 支持；NVIDIA 展示 GPU 加速 Presto 与 LangChain 智能体优化方案。

已检查来源

GitHub Release、NVIDIA Developer Blog

1. PyTorch 2.13.0 Release：FlexAttention 加速 Apple Silicon，新增 nn.LinearCrossEntropyLoss 节省显存

来源 GitHub Release | 类型 GitHub Release | 主题 检索增强与向量模型 时间 07-08 12:39 | 分数 8

是什么 PyTorch 2.13.0 是 PyTorch 深度学习框架的最新稳定版本，带来了多项性能优化和新功能。

通俗解释 想象你正在训练一个大型语言模型，需要处理大量词汇。PyTorch 2.13.0 引入了一个名为 nn.LinearCrossEntropyLoss 的新模块，它把最后的预测计算和损失计算合并在一起，就像把两个步骤合并成一个，从而减少中间数据的存储，最高可节省 4 倍的 GPU 显存。对于使用 Apple Silicon 芯片（如 M1/M2/M3）的 Mac 用户，FlexAttention 操作现在比之前的 SDPA 快约 12 倍，特别适合处理稀疏注意力模式。此外，新的 CuTeDSL 后端为 GPU 操作提供了除 Triton 之外的另一种高性能代码路径，编译速度更快。

主要作用 提升 PyTorch 在 Apple Silicon 上的性能，降低大词汇量语言模型训练的显存需求，并为 GPU 操作提供更快的编译选项。

核心功能 FlexAttention 在 Apple Silicon (MPS) 上实现约 12 倍加速，并支持 CUDA 上的确定性反向传播。；nn.LinearCrossEntropyLoss 原型功能，将预测与损失计算合并，峰值显存降低最多 4 倍。；CuTeDSL 'Native DSL' 后端作为 Inductor 的第二个高性能代码路径，编译更快。；新增 torchcomms 通信后端，优化分布式训练。

对比判断 FlexAttention 在 Apple Silicon 上比 SDPA 快约 12 倍；nn.LinearCrossEntropyLoss 相比传统方法可节省最多 4 倍显存。

适合谁 使用 PyTorch 进行深度学习研究的开发者、训练大语言模型的团队、以及使用 Apple Silicon Mac 进行模型训练的 AI 工程师。

直达链接 <https://github.com/pytorch/pytorch/releases/tag/v2.13.0>

2. llama.cpp b9925 : CUDA 支持 f16 格式的 GGML_OP_SET_ROWS 操作

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 时间 07-08 11:52 | 分数 7

是什么	llama.cpp 是一个用于在本地运行大型语言模型（如 LLaMA）的开源推理引擎，b9925 是其最新版本。
通俗解释	llama.cpp 让你可以在自己的电脑上运行像 LLaMA 这样的 AI 模型，而不需要联网。这次更新主要针对使用 NVIDIA 显卡（CUDA）的用户，增加了对 f16（半精度浮点数）格式的 GGML_OP_SET_ROWS 操作的支持。简单来说，这个操作在模型推理中用于处理行数据，支持 f16 格式可以让计算更快、更省显存。同时，该版本继续提供 macOS（Apple Silicon 和 Intel）、iOS、Linux（x64、arm64、s390x）等多种平台的预编译二进制文件，方便用户直接下载使用。
主要作用	提升 llama.cpp 在 CUDA 上的性能，特别是针对 f16 数据格式的行操作，同时保持跨平台支持。
核心功能	CUDA 后端新增对 f16 格式的 GGML_OP_SET_ROWS 操作支持。；提供 macOS（arm64 和 x64）、iOS、Linux（x64、arm64、s390x）的预编译二进制文件。；继续优化本地推理体验。
对比判断	暂无可信公开对比数据。
适合谁	需要在本地或边缘设备上运行大语言模型的开发者、AI 爱好者和隐私敏感用户。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9925>

3. NVIDIA 博客：在 NVIDIA GB200 NVL72 上使用 GPU 加速 Presto 运行低延迟分析工作负载

来源 NVIDIA Developer Blog | 类型 官方发布 主题 推理性能与基础设施 时间 07-08 11:05 | 分数 7

是什么	这是一篇 NVIDIA 官方博客，介绍如何利用 GPU 加速 Presto（一个开源分布式 SQL 引擎）在 NVIDIA GB200 NVL72 系统上实现低延迟分析查询。
通俗解释	Presto 是一个可以快速查询海量数据的 SQL 引擎，常用于大数据分析。传统上它运行在 CPU 上，但 NVIDIA 将其与 GPU 结合，让查询速度更快。例如，一个需要扫描数十亿行数据的聚合查询，在 GPU 上可能只需几秒，而 CPU 需要几分钟。这篇博客详细说明了如何在 NVIDIA 最新的 GB200 NVL72 硬件上配置和优化 Presto，以实现极低的查询延迟。
主要作用	展示 GPU 加速 Presto 在 NVIDIA GB200 NVL72 上的性能优势，为大数据分析团队提供优化指南。
核心功能	利用 GPU 并行计算能力加速 Presto 的查询执行。；针对 NVIDIA GB200 NVL72 系统进行优化。；提供低延迟分析工作负载的配置建议。
对比判断	暂无可信公开对比数据。
适合谁	大数据工程师、数据分析师、以及使用 Presto 进行交互式查询的团队。

直达链接 <https://developer.nvidia.com/blog/running-low-latency-analytical-workloads-with-gpu-accelerated-presto-on-nvidia-gb200-nvl72/>

4. NVIDIA 博客：为 NVIDIA Nemotron 3 Ultra 创建 LangChain Deep Agents Harness Profile 以提升性能

来源 NVIDIA Developer Blog | 类型 官方发布 主题 智能体与开发者平台 时间 07-08 10:00 | 分数 7

是什么	这是一篇 NVIDIA 官方博客，介绍如何为 NVIDIA Nemotron 3 Ultra 模型创建 LangChain Deep Agents Harness Profile，以优化智能体系统的性能。
通俗解释	智能体系统（Agentic systems）是能自主执行任务的 AI 程序，比如一个能帮你预订机票的聊天机器人。这类系统通常需要在准确性和成本之间权衡：使用最强大的模型（如 GPT-4）准确率高但成本也高。NVIDIA 的 Nemotron 3 Ultra 是一个高性能模型，而 LangChain 是一个流行的智能体开发框架。这篇博客教你如何创建一个 Harness Profile，相当于一个配置文件，让 Nemotron 3 Ultra 在 LangChain 中运行得更高效，在保持高准确率的同时降低计算成本。
主要作用	帮助开发者优化基于 NVIDIA Nemotron 3 Ultra 的智能体系统，在准确性和成本之间取得更好平衡。
核心功能	为 Nemotron 3 Ultra 定制 LangChain Deep Agents Harness Profile。；提升智能体系统的性能，降低推理成本。；提供具体的配置和优化方法。
对比判断	暂无可信公开对比数据。
适合谁	使用 LangChain 开发智能体应用的开发者、AI 研究员，以及关注模型部署成本的团队。
直达链接	https://developer.nvidia.com/blog/create-a-langchain-deep-agents-harness-profile-for-nvidia-nemotron-3-ultra-to-improve-performance/

以上信息均来自候选源，请以官方发布为准。