

# 重大 AI 更新提醒

07-09 | llama.cpp 发布两个新版本，优化 AMD GPU 与 CUDA 推理性能

## 本期导读

本期聚焦 llama.cpp 的两个最新 GitHub Release，分别针对 AMD GPU 启用不安全数学优化以提升速度，以及修复 CUDA 后端的蛇形融合匹配器，确保与 CPU/Metal 行为一致。这些更新直接提升了本地大模型推理的效率与兼容性。

## 已检查来源

GitHub Release

## 1. ggml-org/llama.cpp release b9938: 为 AMD GPU 启用不安全数学优化，提升推理速度

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 07-09 05:08 | 分数 7

**是什么** 这是 llama.cpp 项目的一个版本发布（b9938），主要变更是在 AMD/HIP 后端启用了 `funsafe-math-optimizations` 编译标志，使得 AMD GPU 能够像 CUDA 一样使用快速数学运算，从而加速模型推理。

**通俗解释** 想象一下，你在做数学题时，如果允许一些近似计算（比如忽略极小的误差），速度会快很多。这个更新就是让 AMD 显卡在运行 AI 模型时，也采用这种 近似但更快 的计算方式。之前 CUDA（NVIDIA 显卡）已经用了，现在 AMD 用户也能享受到同样的加速效果。而且，开发者特意避开了更激进的 `ffast-math` 选项，因为它会导致计算错误（比如产生 NaN），所以只用了 `funsafe-math-optimizations`，在保证正确性的前提下提升速度。

**主要作用** 解决 AMD GPU 在 llama.cpp 上推理速度慢于 NVIDIA GPU 的问题，通过启用快速数学优化来缩小性能差距，让 AMD 用户也能获得更流畅的本地大模型体验。

**核心功能** 为 AMD/HIP 后端启用 `funsafe-math-optimizations` 编译标志；避免使用 `ffast-math` 以防止 NaN 和编译错误；与 CUDA 后端的快速数学行为对齐；提供 macOS Apple Silicon、Intel、Linux 等多平台二进制包

**对比判断** 暂无可信公开对比数据，但该优化旨在使 AMD GPU 的推理速度接近 CUDA 水平。

**适合谁** 使用 AMD GPU 进行本地大模型推理的开发者、AI 爱好者；需要优化推理性能的 llama.cpp 用户；关注跨平台 AI 部署的团队。

**直达链接** <https://github.com/ggml-org/llama.cpp/releases/tag/b9938>

## 2. ggml-org/llama.cpp release b9937: 修复 CUDA 蛇形融合匹配器，对齐 CPU/Metal 行为

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 07-09 03:30 | 分数 7

|      |                                                                                                                                                                                                                                       |
|------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 是什么  | 这是 llama.cpp 的另一个版本发布（b9937），修复了 CUDA 后端中蛇形融合（snake fusion）操作的类型谓词和连续性检查，使其与 CPU 和 Metal 后端的匹配逻辑一致，避免因类型不匹配或非连续内存导致的计算错误。                                                                                                             |
| 通俗解释 | 蛇形融合是一种优化技术，它把多个数学操作合并成一个，减少计算步骤。但之前 CUDA 版本的匹配规则有 bug：它要求输入数据的类型完全一致，而实际中有些参数（比如 a 和 inv_b）总是 32 位浮点数，但其他数据可能是 16 位。这导致很多本可以融合的操作没有被融合，退回到更慢的路径。另外，如果数据在内存中不是连续排列的，融合后的内核会读到错误数据。这次更新修正了这两个问题，让 CUDA 的行为和 CPU、Metal 一样，从而正确触发更多融合优化。 |
| 主要作用 | 修复 CUDA 后端蛇形融合的匹配逻辑，确保更多操作能被正确融合，提升推理效率，同时避免因内存布局问题导致的错误结果。                                                                                                                                                                           |
| 核心功能 | 修正蛇形融合的类型谓词，允许 a 和 inv_b 为 F32 类型；拒绝非连续操作数的融合，防止读取错误数据；与 CPU、Vulkan、Metal 后端的匹配逻辑对齐；提供多平台二进制包                                                                                                                                         |
| 对比判断 | 暂无可信公开对比数据，但修复后 CUDA 后端的融合行为与 CPU/Metal 一致，预期能提升部分模型的推理速度。                                                                                                                                                                            |
| 适合谁  | 使用 NVIDIA GPU 运行 llama.cpp 的开发者；关注模型推理正确性和性能优化的研究人员；需要跨后端一致行为的 AI 应用开发者。                                                                                                                                                              |

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9937>

以上更新均来自 llama.cpp 官方 GitHub Release，建议用户根据自身硬件环境升级以获取最佳性能。