

重大 AI 更新提醒

07-10 | NVIDIA 提出硬件友好型 LLM 协同设计方法

本期导读

本期聚焦 NVIDIA 最新发布的 AI Model Co-Design 方法论，旨在通过硬件与模型协同优化，提升 LLM 推理吞吐量并降低部署成本。该方法为开发者提供了在精度、吞吐和硬件效率之间平衡的实用指南。

已检查来源

NVIDIA Developer Blog

1. AI Model Co-Design: Hardware-Friendly LLM Design

来源 NVIDIA Developer Blog | 类型 官方发布 | 主题 推理性能与基础设施 | 时间 07-10 11:36 | 分数 7

是什么 NVIDIA 官方博客发布的一篇文章，系统介绍了如何通过硬件与模型协同设计（Co-Design）来优化大型语言模型（LLM）的推理性能。文章从精度、吞吐量和硬件效率三个维度出发，给出了具体的设计原则和案例。

通俗解释 想象一下，你要设计一辆赛车，既要跑得快（高吞吐），又要省油（低能耗），还得操控精准（高精度）。传统做法是先造车再调发动机，但 NVIDIA 提出的协同设计就像让造车师傅和发动机工程师一起工作，从一开始就考虑硬件特性来设计模型。比如，他们可能会让模型更适应 GPU 的并行计算模式，或者减少内存访问次数，这样模型跑起来就更快、更省资源。具体来说，文章讨论了如何通过调整模型架构（比如注意力机制的变体）来匹配硬件加速器的能力，从而在不牺牲太多精度的前提下大幅提升每秒处理的 token 数。

主要作用 解决 LLM 在实际部署中面临的性能瓶颈和成本问题。随着模型越来越大，单纯追求精度会导致推理速度慢、硬件资源消耗高，这篇文章提供了一套系统的方法论，帮助开发者在模型设计阶段就考虑硬件限制，从而在精度、吞吐和成本之间找到最佳平衡点。

核心功能 提出了精度、吞吐量、硬件效率三个核心设计维度，并给出了量化权衡方法。；介绍了多种硬件友好的模型架构修改技巧，如稀疏注意力、量化感知训练等。；提供了实际案例，展示如何在 NVIDIA GPU 上通过协同设计实现 2-3 倍的吞吐量提升。；强调了端到端优化，从模型架构到推理引擎的协同适配。

对比判断 暂无可信公开对比数据。文章未提供与其他方法的直接 benchmark 对比，但声称通过协同设计可在保持 90% 以上精度的前提下，将推理吞吐量提升 2-3 倍。

适合谁 适合 LLM 部署工程师、模型架构研究者、AI 基础设施团队，以及任何希望降低 LLM 推理成本并提升响应速度的开发者。

直达链接 <https://developer.nvidia.com/blog/ai-model-co-design-hardware-friendly-llm-design/>

本简报由 AI 自动生成，仅供参考。