

重大 AI 更新提醒

07-12 | llama.cpp 服务端重大重构，提升流式 API 稳定性

本期导读

本期聚焦 llama.cpp 最新版本 b9971，该版本对服务端流式 API 进行了深度重构，移除了非线性安全的调用，显著提升了高并发场景下的稳定性与性能。适合自托管 LLM 推理服务的开发者关注。

已检查来源

GitHub Release

1. llama.cpp b9971: 服务端流式 API 重构，移除 spipe 并优化线程安全

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 07-12 07:36 | 分数 7

是什么 这是 llama.cpp 项目的一个 GitHub Release (b9971)，主要对服务端 (server) 的流式 API 进行了重构，移除了 server_http_res 中的 spipe 组件，并修复了非线性安全的 rd.stop() 调用。

通俗解释 llama.cpp 是一个让大语言模型 (如 LLaMA) 在普通电脑上运行的 C++ 库。这次更新就像给它的 网络服务 部分做了一次大扫除：以前处理流式输出 (比如 AI 一个字一个字地回复) 时，内部有个叫 spipe 的管道容易出问题，而且停止请求的代码在多线程下不安全。现在把这些都改掉了，就像把老旧的单车道改成多车道立交桥，多个用户同时请求时更稳定、更快。

主要作用 解决服务端在高并发流式请求下的线程安全问题，提升 API 的稳定性和响应速度，为开发者提供更可靠的本地推理服务。

核心功能 重构 server_stream 函数，移除 spipe 组件，简化数据流；修复非线性安全的 rd.stop() 调用，避免竞态条件；更新开发者文档，提供改进后的 API 使用指南；提供 macOS (Apple Silicon/Intel)、iOS、Linux 等多平台二进制包

对比判断 暂无可信公开对比数据

适合谁 适合使用 llama.cpp 自托管 LLM 推理服务的开发者、需要稳定流式 API 的 AI 应用后端工程师、以及研究本地模型部署的团队。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9971>

本简报基于候选源自动生成，请以官方发布为准。