

重大 AI 更新提醒

07-12 | llama.cpp 修复 CUDA 内存查询崩溃

本期导读

本期聚焦 llama.cpp 最新版本 b9974，修复了 CUDA 设备在无空闲内存时查询内存导致崩溃的关键问题，提升了推理稳定性。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b9974: 修复 CUDA 设备无空闲内存时查询内存导致崩溃的问题

来源 GitHub Release | 类型 GitHub Release | 主题 检索增强与向量模型 时间 07-12 09:16 | 分数 7

是什么 这是 llama.cpp 项目的一个新版本（b9974），主要修复了在 CUDA 设备没有空闲内存时，调用 `cudaMemGetInfo()` 查询内存信息会导致程序崩溃的 bug。

通俗解释 想象一下，你的电脑显卡（GPU）内存已经满了，这时你试图查看它还剩多少空间，结果系统直接死机了。这个 bug 就是类似的情况：当 CUDA 设备内存不足时，查询内存的操作本身会触发 内存不足 错误，导致程序崩溃。llama.cpp 的这次更新让这个错误不再致命，而是把该设备的内存设为 0，这样系统就不会尝试把模型层放到这个设备上，从而避免崩溃。

主要作用 解决在 CUDA 设备内存不足时，llama.cpp 启动或运行过程中因查询内存而意外崩溃的问题，提升推理服务的稳定性和用户体验。

核心功能 将 `cudaMemGetInfo()` 调用中的致命错误改为非致命错误；当设备无空闲内存时，自动将其总内存和空闲内存均设为 0；下游的分配算法不会尝试将模型层放到该设备上，避免进一步错误；同时修复了在 CUDA 版本中用户显式指定 `dev none` 时的崩溃问题

对比判断 暂无可信公开对比数据

适合谁 使用 llama.cpp 在 CUDA 环境下进行推理的开发者、运维人员，以及依赖 llama.cpp 的 AI 应用团队。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9974>

本简报由 AI 自动生成，仅供参考。