

重大 AI 更新提醒

07-12 | llama.cpp 修复多模态模型声明逻辑

本期导读

本期重点关注 llama.cpp 最新版本 b9980 的发布，该版本修复了多模态模型声明逻辑，确保当 mmproj 被显式禁用时，模型不会错误地声明支持图像 音频输入。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b9980: 修复多模态模型声明逻辑

来源 GitHub Release | 类型 GitHub Release | 主题 多模态理解 时间 07-12 19:07 | 分数 7

是什么 这是 llama.cpp 项目的一个新版本（b9980），主要修复了服务器端多模态模型声明的逻辑。当用户通过模型预设或命令行参数显式禁用 mmproj（多模态投影）时，模型将不再被错误地标记为支持图像或音频输入，从而避免 API 端点返回不准确的能力声明。

通俗解释 想象你有一个能看图片的 AI 助手，但如果你故意关掉了它的 眼睛（mmproj），它就不应该再声称自己能看图片。之前 llama.cpp 的服务器 API 会错误地继续宣称该模型支持多模态输入，导致用户以为它能处理图片或音频，但实际上不行。这次更新就是修复了这个 bug，让 API 返回的信息更准确。例如，如果你用命令行参数 `no-mmproj-auto` 禁用了多模态投影，那么 `v1/models` 端点就不会再显示该模型支持图像或音频输入。

主要作用 解决服务器端多模态模型能力声明不准确的问题，避免开发者或用户因错误信息而误用模型，提升 API 的可靠性和用户体验。

核心功能 修复了当 mmproj 被显式禁用时，模型仍被标记为多模态的 bug；改进了 `v1/models` 端点的能力声明逻辑，使其更准确；提供了针对 macOS（Apple Silicon 和 Intel）、iOS 以及 Linux 的预编译二进制包

对比判断 暂无可信公开对比数据

适合谁 适合使用 llama.cpp 部署大语言模型的开发者、运维人员，特别是那些需要精确控制模型多模态能力的团队，以及依赖 `v1/models` 端点进行模型发现的应用开发者。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9980>

以上信息基于候选源，请以官方发布为准。