

重大 AI 更新提醒

07-13 | llama.cpp 发布 b9992，重构 CUDA MMQ 内核配置

本期导读

本期聚焦 llama.cpp 最新版本 b9992，该版本对 CUDA 下的 MMQ 内核配置进行了重构，并移除了遗留代码，同时为 Blackwell 架构修复了配置问题。此次更新有望提升 NVIDIA GPU 上的推理性能，尤其对使用 CUDA 的开发者意义重大。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b9992: CUDA: refactor MMQ kernel configuration

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 07-13 16:04 | 分数 7

是什么	llama.cpp 是一个用于在本地运行大型语言模型（如 LLaMA）的开源推理引擎，支持 CPU 和 GPU 加速。此次发布的 b9992 版本主要对 CUDA 下的 MMQ（矩阵乘法量化）内核配置进行了重构，修复了 Blackwell 架构的配置问题，并移除了遗留代码。
通俗解释	想象一下，你有一个巨大的乐高城堡（大型语言模型），你想快速把它拆解并重新组装（推理）。llama.cpp 就像一套高效的拆解工具。这次更新相当于改进了工具中用于处理特定类型乐高积木（量化矩阵乘法）的机械臂（CUDA 内核）。通过重新调整机械臂的配置，让它能更精准、更快速地抓取积木，尤其是在最新的乐高平台（Blackwell GPU）上。同时，还清理了旧的不再需要的零件（遗留代码），让工具更干净、更高效。
主要作用	提升 llama.cpp 在 NVIDIA GPU 上的推理性能，特别是针对 Blackwell 架构的优化，同时通过代码重构提高可维护性和执行效率。
核心功能	重构 CUDA MMQ 内核配置，优化矩阵乘法量化计算路径；修复 Blackwell 架构的配置，确保在新一代 GPU 上正确运行；移除遗留代码，减少冗余，提升代码质量和执行效率
对比判断	暂无可信公开对比数据
适合谁	使用 llama.cpp 在 NVIDIA GPU 上进行本地推理的开发者、AI 应用部署工程师、以及关注大模型推理性能优化的研究人员。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b9992>

以上信息基于候选源，请以官方发布为准。