

重大 AI 更新提醒

07-14 | Google 发布 Qwen 3.5-397B MoE 在 Ironwood TPU 上的系统优化方案

本期导读

本期聚焦 Google 在 Ironwood TPU 上优化 Qwen 3.5-397B MoE 模型推理的工程实践，实现了最高 4.7 倍加速，为大规模 MoE 模型部署提供了重要参考。

已检查来源

Google Developers Blog

1. Systems Engineering Playbook: Optimizing Qwen 3.5-397B MoE on Ironwood (TPU7x)

来源 Google Developers Blog | 类型 官方发布 主题 检索增强与向量模型 时间 07-14 15:53 | 分数 8

是什么 Google 发布的一篇工程博客，详细介绍了如何在 Ironwood TPU (TPU7x) 上优化 3970 亿参数的 Qwen 3.5 MoE (混合专家) 模型的推理性能。

通俗解释 想象一下，你有一个巨大的图书馆（397B 参数的模型），每次有人问问题，都需要从所有书里找答案，非常慢。MoE 模型就像把图书馆分成很多小房间（专家），每次只让少数几个房间的人回答，但协调这些房间需要复杂的通信。Google 的工程师们设计了一套 交通系统：他们用混合数据并行和专家并行 (DP+EP) 来分配任务，就像给每个房间分配不同的快递员；还发明了 层级归约 分散 通信方法，让快递员之间高效传递信息；最后，他们为 TPU 编写了专门的 加速指令（如 Batched Ragged Page Attention 和 Gated DeltaNet 块），让硬件跑得更快。结果，对于需要大量预填充 (prefill) 的任务（比如处理长文档），速度提升了 4.7 倍。

主要作用 解决在 Ironwood TPU 上部署超大 MoE 模型时遇到的硬件分片限制和通信瓶颈，提供一套可复用的优化方法，帮助开发者在实际生产环境中高效运行千亿级模型。

核心功能 混合数据并行与专家并行 (DP+EP) 拓扑，突破硬件分片限制；自定义层级归约 散射通信融合，优化跨设备 token 路由；硬件感知的自定义内核：Batched Ragged Page Attention 和全融合 Gated DeltaNet (GDN) 块；实现 HBM 带宽和 TensorCore MXU 饱和，接近理论峰值吞吐

对比判断 在预填充密集型工作负载下，相比未优化版本实现最高 4.7 倍推理加速。其他基准数据暂无可信公开对比。

适合谁 适合部署大规模 MoE 模型的 AI 工程师、TPU 用户、系统优化研究者，以及关注千亿参数模型推理效率的团队。

直达链接 <https://developers.googleblog.com/systems-engineering-playbook-optimizing-qwen-35-397b-moe-on-ironwood-tpu7x/>

本简报由 AI 自动生成，信息基于候选源，请以原文为准。