

重大 AI 更新提醒

07-15 | llama.cpp 提升 USM 缓冲区大小，支持更大模型

本期导读

本期聚焦 llama.cpp 最新 release b10017，针对 Intel GPU 的 USM 系统分配缓冲区大小从 1 GiB 提升至 4 GiB，以支持在显存不足时运行更大模型（如 Qwen3.5-35B-A3B-Q8）。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b10017: sycl: Increase minimum buffer size for USM system allocations

来源 GitHub Release | 类型 GitHub Release | 主题 检索增强与向量模型 时间 07-15 06:37 | 分数 7

是什么 这是 llama.cpp 项目的一个新版本（b10017），主要针对 SYCL 后端（用于 Intel GPU）的 USM（统一共享内存）系统分配进行了优化。具体来说，它将最小缓冲区大小从 1 GiB 提高到 4 GiB，并添加了调试信息以更好地跟踪 USM 系统分配。

通俗解释 想象一下，你的电脑显存只有 8GB，但你想运行一个需要 10GB 显存的 AI 模型。以前，llama.cpp 会直接拒绝，因为显存不够。现在，通过提高缓冲区大小，它允许你 超额使用 显存，把一部分数据放在系统内存中，从而让大模型也能在显存较小的设备上运行。例如，在 Intel B70 GPU 上运行 Qwen3.5-35B-A3B-Q8 模型时，这个改进就很有用。

主要作用 解决在显存不足时无法运行大模型的问题，通过允许系统内存与设备内存协同工作，扩展了 llama.cpp 在 Intel GPU 上的模型兼容性。

核心功能 将 USM 系统分配的最小缓冲区大小从 1 GiB 提升至 4 GiB，基于实际测试（如 Qwen3.5-35B-A3B-Q8 在 B70 上的运行）；添加调试消息，便于追踪 USM 系统分配情况；仅影响 SYCL 后端，不影响其他后端（如 CUDA、Metal）

对比判断 暂无可信公开对比数据

适合谁 适合使用 Intel GPU（如 Arc 系列）运行 llama.cpp 的开发者，特别是需要运行超过显存容量的大模型（如 Qwen3.5-35B-A3B-Q8）的用户。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10017>

本简报基于候选源自动生成，请以官方发布为准。