

重大 AI 更新提醒

07-15 | llama.cpp 发布 b10025，优化 CUDA 量化张量拼接

本期导读

本期聚焦 llama.cpp 最新版本 b10025，该版本在 CUDA 后端放宽了量化张量拼接的连续性要求，提升了推理灵活性与兼容性。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b10025: CUDA 放宽量化张量拼接的连续性要求

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 07-15 11:10 | 分数 7

是什么 llama.cpp 是一个高性能的 LLM 推理引擎，支持多种后端（CPU、CUDA、Metal 等）。本次 b10025 版本主要针对 CUDA 后端，放宽了量化张量在拼接（concat）操作时的内存连续性要求，并增加了相应的测试用例。

通俗解释 想象你在拼乐高，之前要求所有积木必须按顺序紧密排列（连续内存）才能拼接，现在允许积木之间有间隙或顺序打乱（非连续内存）也能拼起来。这意味着模型在推理时，不同部分的张量（数据块）不需要严格连续存放，系统可以更灵活地管理内存，从而支持更复杂的模型结构或减少内存碎片。例如，当运行一个大型语言模型时，不同层的输出可能分散在显存的不同位置，以前需要先复制到连续区域再拼接，现在可以直接操作，节省时间和显存。

主要作用 提升 llama.cpp 在 CUDA 后端处理量化模型时的兼容性和性能，减少因内存连续性限制导致的额外拷贝开销，使更多模型结构（如需要频繁拼接的 MoE 模型）能高效运行。

核心功能 放宽 CUDA 后端量化张量拼接的连续性要求；新增非连续量化张量拼接的测试用例；同时更新了 ggml 核心库的连续性要求

对比判断 暂无可信公开对比数据

适合谁 使用 llama.cpp 在 NVIDIA GPU 上部署量化 LLM 的开发者、研究者和运维人员，尤其是需要处理复杂模型结构（如混合专家模型）或面临显存碎片问题的用户。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10025>

以上信息基于候选源，请以官方发布为准。