

重大 AI 更新提醒

07-16 | llama.cpp 连续发布两个版本，修复 Adreno 850 GPU 兼容性并优化 CUDA 量化提取

本期导读

llama.cpp 在 7 月 15-16 日连续发布 b10035 和 b10036 两个版本。b10036 主要针对 Adreno 850 GPU 的编译器问题，禁用了 Flash Attention 和 MoE 权重重打包；b10035 则通过 CUDA 的 `byte_perm` 指令优化了 Q1_0 量化元素的提取效率。两个版本均提供了 macOS、iOS、Linux 等多平台二进制包。

已检查来源

GitHub Release

1. llama.cpp b10036：修复 Adreno 850 GPU 编译器兼容性，禁用 FA 和 MoE 权重重打包

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 07-16 00:31 | 分数 7

是什么 这是 llama.cpp 的第 b10036 次发布，主要针对 Adreno 850 GPU 的 OpenCL 后端进行了编译器兼容性修复。由于编译器问题，该版本禁用了 Flash Attention (FA) 和 MoE 权重的重打包功能，以确保在 Adreno 850 上稳定运行。同时修复了 DX 编译器版本解析和清理工作。

通俗解释 想象一下，你有一个非常强大的 GPU (Adreno 850)，但它的编译器 (把代码翻译成 GPU 能理解的指令的工具) 有一些 bug，导致某些高级功能 (比如 Flash Attention 和 MoE 权重重打包) 无法正常工作。llama.cpp 的这次更新就像给这个 GPU 打了一个补丁，暂时关闭了这些有问题的功能，让模型能稳定运行。Flash Attention 是一种加速注意力计算的技术，MoE 权重重打包是为了优化混合专家模型的权重布局，现在为了兼容性暂时禁用，可能会略微影响性能，但保证了正确性。

主要作用 解决 Adreno 850 GPU 用户在运行 llama.cpp 时遇到的编译器兼容性问题，确保模型推理的稳定性和正确性。对于使用该 GPU 的开发者来说，这是必要的更新。

核心功能 针对 Adreno 850 GPU 的 OpenCL 编译器兼容性修复；禁用 Flash Attention 以避免编译器错误；禁用 MoE 权重重打包以避免编译器错误；修复 DX 编译器版本解析和代码清理

对比判断 暂无可信公开对比数据

适合谁 使用 Adreno 850 GPU (常见于高通骁龙移动平台) 运行 llama.cpp 的开发者；需要 OpenCL 后端的用户；关注移动端或嵌入式设备上大模型推理的工程师。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10036>

2. llama.cpp b10035 : CUDA 后端通过 byte_perm 指令优化 Q1_0 量化元素提取

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 07-15 23:59 | 分数 7

是什么	这是 llama.cpp 的第 b10035 次发布，主要针对 CUDA 后端进行了性能优化。具体来说，它使用 CUDA 的 <code>byte_perm</code> 指令来提取 Q1_0 量化格式中的元素。Q1_0 是一种极低比特的量化格式，每个权重只占 1 比特，但提取过程需要特殊处理。 <code>byte_perm</code> 是 NVIDIA GPU 上的一个字节置换指令，可以高效地重组字节，从而加速量化权重的解包。
通俗解释	想象一下，你有一堆压缩得很小的数据包（Q1_0 量化），每个包只有 1 比特信息，但你需要把它们一个个拆开才能使用。以前拆包的方法比较慢，现在发现了一个更快的工具（ <code>byte_perm</code> 指令），就像用一把特制的钥匙一下子就能打开多个包。这个优化让 CUDA 上的模型推理速度更快，尤其是在使用 1 比特量化时。
主要作用	提升 llama.cpp 在 CUDA 后端上处理 Q1_0 量化模型的推理速度，减少量化权重的解包开销，从而降低延迟或提高吞吐量。
核心功能	使用 CUDA <code>__byte_perm</code> 指令优化 Q1_0 量化元素提取；针对 NVIDIA GPU 的底层指令级优化；保持与现有 CUDA 后端的兼容性
对比判断	暂无可信公开对比数据
适合谁	使用 NVIDIA GPU 运行 llama.cpp 的开发者；对极低比特量化（如 Q1_0）感兴趣的研究者；需要最大化推理性能的部署工程师。
直达链接	https://github.com/ggml-org/llama.cpp/releases/tag/b10035

两个版本均为增量更新，建议根据自身 GPU 类型选择升级。b10036 主要面向 Adreno 850 用户，b10035 面向 CUDA 用户。