

重大 AI 更新提醒

07-16 | llama.cpp 修复 AMD APU 集成 GPU 推理问题

本期导读

本期关注 llama.cpp 最新版本 b10040，该版本修复了在 AMD APU/UMA 平台上使用集成 GPU 进行推理时出现的 host buffer 错误，确保 ROCm 用户能正常利用集成 GPU 加速。

已检查来源

GitHub Release

1. llama.cpp b10040: 修复 AMD APU 集成 GPU 的 CUDA/HIP 兼容性问题

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 07-16 04:55 | 分数 7

是什么 llama.cpp 是一个流行的 C/C++ 实现的 LLaMA 模型推理引擎，支持多种硬件后端。本次 b10040 版本主要修复了在 AMD APU（如 Ryzen 系列）或 UMA（统一内存架构）设备上，使用 HIP/ROCm 后端时集成 GPU 无法正确使用 host buffer 的问题。

通俗解释 想象一下，你的电脑里有一个集成显卡（比如 AMD APU），它和 CPU 共享内存。之前 llama.cpp 为了修复 NVIDIA Jetson Orin 上的一个 bug，强制把所有 GPU 都标记为 非集成 设备，这导致 AMD 的集成 GPU 无法正常使用 CPU 内存中的缓冲区（host buffer），推理时就会出错。这次更新相当于给 AMD 的集成 GPU 开了个 特例，让它们能正确识别自己的集成身份，从而正常使用共享内存，而 NVIDIA 的修复仍然保留。

主要作用 解决在 AMD APU/UMA 平台上使用 llama.cpp 进行模型推理时，因集成 GPU 被错误标记而导致的 host buffer 错误，确保 ROCm 用户能充分利用集成 GPU 加速推理。

核心功能 修复了 HIP 构建中 prop.integrated 标志被错误强制设为 false 的问题；仅对非 HIP（即 CUDA）构建保留 Jetson Orin 的 workaround，不影响 AMD 平台；恢复了 AMD APU/UMA 设备上集成 GPU 的 host buffer 支持；保持了与 NVIDIA Jetson Orin 的兼容性修复

对比判断 暂无可信公开对比数据

适合谁 使用 AMD APU（如 Ryzen 系列）或 UMA 架构设备进行本地推理的开发者；依赖 ROCm 后端的 llama.cpp 用户；需要在集成 GPU 上运行大语言模型的边缘计算场景。

直达链接 <https://github.com/qgml-org/llama.cpp/releases/tag/b10040>

本简报由 AI 自动生成，请以官方发布为准。