

重大 AI 更新提醒

07-16 | llama.cpp 支持 CUDA 虚拟设备，多 GPU 推理更灵活

本期导读

本期聚焦 llama.cpp 最新版本 b10043，该版本引入了 CUDA 虚拟设备支持，允许用户更灵活地管理多 GPU 推理资源，并优化了 NCCL 路径禁用逻辑。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b10043: 支持 CUDA 虚拟设备，优化多 GPU 推理

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 07-16 09:02 | 分数 7

是什么 llama.cpp 是一个高性能的 LLM 推理引擎，支持在 CPU 和 GPU 上运行大语言模型。本次 b10043 版本主要新增了对 CUDA 虚拟设备的支持，允许用户将多个物理 GPU 组合成一个逻辑设备，从而更高效地分配推理任务。同时，当使用虚拟设备时，会自动禁用 NCCL 路径，避免通信冲突。

通俗解释 想象你有多块 GPU，但每块显存都不够单独运行一个大模型。以前你需要手动分配每层到哪块卡，很麻烦。现在 llama.cpp 支持 CUDA 虚拟设备，就像把多块小显存拼成一块大显存，系统自动帮你分配任务，你只需要指定使用虚拟设备即可。比如你有两块 24GB 的 GPU，虚拟设备可以让你运行需要 40GB 显存的模型，而无需手动管理数据在哪块卡上。

主要作用 解决多 GPU 环境下推理资源管理复杂的问题，让开发者无需手动分配模型层到各 GPU，降低使用门槛，同时提升多卡利用率。

核心功能 支持 CUDA 虚拟设备：将多个物理 GPU 抽象为一个逻辑设备，简化多 GPU 推理配置。；自动禁用 NCCL 路径：当检测到虚拟设备时，自动关闭 NCCL 通信，避免冲突。；设备标签优化：在描述中明确标注虚拟设备，方便调试和监控。；新增 GPUx2 服务器 CI 作业：确保多 GPU 场景的稳定性。

对比判断 暂无可信公开对比数据

适合谁 适合使用多 GPU 进行本地 LLM 推理的开发者、AI 应用部署工程师，以及需要在大模型推理中优化资源利用的研究者。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10043>

本简报由 AI 自动生成，仅供参考。