

重大 AI 更新提醒

07-18 | llama.cpp 修复 DeepSeek-V4 量化问题

本期导读

本期聚焦 llama.cpp 最新版本 b10067，该版本修复了 DeepSeek-V4 模型量化时因路由表被错误量化而失败的关键问题，确保模型在本地高效运行。

已检查来源

GitHub Release

1. llama.cpp b10067: 修复 DeepSeek-V4 量化时 i32 路由表被错误量化的问题

来源 GitHub Release | 类型 GitHub Release | 主题 开发者生态与数据工具 | 时间 07-18 07:12 | 分数 7

是什么 llama.cpp 是一个用于在本地运行大语言模型的开源 C++ 推理框架，支持多种量化方式以降低模型内存占用。本次发布 b10067 版本，修复了量化 DeepSeek-V4 模型时的一个 bug：模型中的 `ffn_gate_tid2eid` 张量是一个整数索引表（i32 类型），用于将 token ID 映射到专家 ID，但之前未被加入量化排除列表，导致量化工具尝试将其转换为浮点类型而失败。

通俗解释 想象你有一本字典，里面每个词条对应一个数字编号（整数）。现在你想把字典压缩成更小的版本，但压缩工具误以为所有内容都是可以压缩的数值，结果把编号也当成普通数字去处理，导致压缩失败。llama.cpp 这次更新就是告诉压缩工具：这个编号表是整数，别动它！这样 DeepSeek-V4 模型就能顺利量化，在普通电脑上也能运行。

主要作用 解决 DeepSeek-V4 模型在 llama.cpp 中无法量化的关键问题，让用户能在本地设备上高效运行该模型，避免因量化失败而无法使用。

核心功能 修复了 `ffn_gate_tid2eid` 张量被错误量化的问题，该张量是 i32 类型的 token ID 到 expert ID 的索引表；将 `ffn_gate_tid2eid` 加入量化排除列表，与已有的 `ffn_gate_inp.weight` 一起被跳过量化；确保 DeepSeek-V4 模型在 llama-quant 工具中能正常完成量化流程；提供 macOS Apple Silicon (arm64)、macOS Intel (x64) 和 iOS XCFramework 的预编译二进制文件

对比判断 暂无可信公开对比数据

适合谁 使用 llama.cpp 在本地运行 DeepSeek-V4 模型的开发者、AI 研究人员，以及需要量化大型 MoE 模型以在有限硬件上部署的工程师。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10067>

本简报基于候选源自动生成，请以官方发布为准。