

重大 AI 更新提醒

07-23 | llama.cpp 自动推测 draft 模型类型，简化推理配置

本期导读

本期聚焦 llama.cpp 最新 release，其新增自动从 draft 仓库 sidecar 文件推断推测解码类型的功能，大幅简化多模型推理的配置流程。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b10094: 自动从 draft 仓库 sidecar 推断推测解码类型

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 07-23 13:28 | 分数 7

是什么 这是 llama.cpp 的 b10094 版本发布，主要更新是让推理引擎能自动识别 draft 模型仓库中的 sidecar 文件（如 mtp、dflash、eagle3 等），从而自动设置正确的推测解码类型，无需用户手动指定 spec-type 参数。

通俗解释 推测解码是一种加速大模型推理的技术，它用一个轻量级的 draft 模型快速生成候选 token，再由主模型验证。以前用户需要手动告诉系统 draft 模型是什么类型（比如 mtp、dflash 或 eagle3），否则可能用错。现在 llama.cpp 会自动检查 draft 仓库里的 sidecar 文件（类似模型的 说明书 ），自动匹配正确的类型。例如，你只需指定主模型和 draft 模型的仓库地址，系统就能自动配置好，像这样：llama-server -hf repo:Q3_K_M -hfd repo:Q8_0，无需额外参数。

主要作用 解决多模型推理时配置复杂、容易出错的问题，降低使用门槛，让开发者更专注于模型本身而非工具配置。

核心功能 自动检测 draft 仓库中的 sidecar 文件（mtp、dflash、eagle3 等）；按 mtp dflash eagle3 优先级自动选择推测解码类型；支持通过 spec-type 手动覆盖自动推断结果；向后兼容：无 sidecar 的 draft 仓库仍按完整模型处理

对比判断 暂无可信公开对比数据

适合谁 适合使用 llama.cpp 进行推理部署的开发者、AI 应用工程师，以及需要优化大模型推理速度的研究团队。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10094>

本简报由 AI 自动生成，仅供参考。