

重大 AI 更新提醒

07-31 | llama.cpp 发布新版本，优化 MoE 模型推理性能

本期导读

本期聚焦 llama.cpp 的最新版本 b10205，该版本针对 MoE（混合专家）模型引入了新的 group matmul API，并调整了 fallback 阈值，有望提升推理效率。适合本地模型部署和推理优化的开发者关注。

已检查来源

GitHub Release

1. llama.cpp b10205 发布：新增 ggml-zendnn group matmul API，优化 MoE 推理

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 07-31 08:26 | 分数 7

是什么 这是 llama.cpp 项目的一个新版本（b10205），主要更新了 ggml-zendnn 后端，为 mul_mat_id 操作添加了 group matmul 的直接 API，并调整了 fallback 阈值。

通俗解释 llama.cpp 是一个在本地运行大语言模型的工具，它通过优化底层计算来让模型跑得更快。这次更新针对的是混合专家（MoE）模型，这类模型像是一个团队，每个专家负责不同任务，但需要协调工作。新 API 让团队协作更高效，减少了不必要的沟通，从而加快推理速度。

主要作用 该版本旨在提升 MoE 模型在 llama.cpp 上的推理性能，通过更高效的矩阵乘法实现，减少计算开销，同时为开发者提供更直接的 API 控制。

核心功能 新增 ggml-zendnn group matmul 直接 API，用于 mul_mat_id 操作；调整 MUL_MAT_ID fallback 阈值，根据专家数量进行缩放；提供多平台预编译二进制，包括 macOS、iOS、Linux

对比判断 暂无可信公开对比数据

适合谁 适合使用 llama.cpp 部署本地大模型的开发者、研究 MoE 模型推理优化的工程师，以及需要跨平台推理解决方案的团队。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10205>

以上信息基于候选源，请以官方发布为准。