

重大 AI 更新提醒

08-07 | llama.cpp 发布 CUDA 警告修复版本

本期导读

本期聚焦 llama.cpp 的最新版本 b10301，该版本主要修复了 CUDA 相关的编译警告，提升了代码质量和构建稳定性，适合依赖本地推理的开发者关注。

已检查来源

GitHub Release

1. llama.cpp b10301 发布：修复 CUDA 未使用变量 函数警告

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 08-07 04:59 | 分数 7

是什么 这是 llama.cpp 项目的一个新版本发布，版本号为 b10301。llama.cpp 是一个用 C/C++ 实现的大语言模型推理引擎，支持在多种硬件上运行，包括 CPU、GPU 等。本次更新主要针对 CUDA 代码中的编译警告进行了修复，涉及未使用的变量和函数。

通俗解释 想象一下，你写代码时留下了一些没用的变量或函数，编译器会提醒你，但不会阻止程序运行。这些警告虽然不影响功能，但会让代码看起来不干净，也可能掩盖真正的问题。llama.cpp 这次更新就是清理了这些警告，让代码更整洁，编译时更安静，也减少了潜在的隐患。对于普通用户来说，这个版本可能没有明显的新功能，但会让开发者在编译和调试时更省心。

主要作用 解决 CUDA 编译时的警告问题，提升代码质量和可维护性，为后续开发打下更稳定的基础。对于使用 llama.cpp 在 NVIDIA GPU 上运行模型的开发者，这个版本可以减少编译时的噪音，避免警告干扰问题定位。

核心功能 修复 CUDA 代码中未使用变量和函数的警告；提供多种平台的预编译二进制文件，包括 macOS (Apple Silicon, Intel)、iOS、Linux (x64, arm64, s390x)；macOS Apple Silicon 版本默认启用 KleidiAI，但本次发布中该功能被禁用（见 PR #23780）

对比判断 暂无可信公开对比数据

适合谁 适合使用 llama.cpp 进行本地推理的开发者，尤其是依赖 CUDA 的 NVIDIA GPU 用户，以及需要干净编译环境的项目维护者。

直达链接 <https://github.com/qgml-org/llama.cpp/releases/tag/b10301>

本简报基于 GitHub Release 信息整理，仅供参考。