

重大 AI 更新提醒

08-07 | llama.cpp 发布 b10306，SYCL 后端 GLU 性能优化

本期导读

本期聚焦 llama.cpp 最新版本 b10306，该版本针对 SYCL 后端进行了 GLU 操作的性能优化，并新增了 SWIGLU 性能测试用例，为使用 Intel GPU 的开发者带来显著推理加速。

已检查来源

GitHub Release

1. llama.cpp b10306: SYCL 后端 GLU 扁平路径优化与 SWIGLU 性能测试

来源 GitHub Release | 类型 GitHub Release | 主题 检索增强与向量模型 | 时间 08-07 07:33 | 分数 7

是什么 这是 llama.cpp 的一个新版本发布，主要针对 SYCL 后端（用于 Intel GPU）的 GLU（门控线性单元）操作进行了性能优化，并添加了 SWIGLU 的性能测试用例。

通俗解释 GLU 是一种神经网络中常用的激活函数，它把输入分成两半，一半经过激活函数（如 SiLU），另一半与激活后的结果相乘。在 llama.cpp 中，GLU 操作在推理时很耗时。这次更新通过合并内核、优化内存访问路径，让 GLU 在 Intel GPU 上运行得更快。比如，当输入数据的形状满足特定条件时，可以直接用更简单的计算方式，避免复杂的索引计算，就像走一条直路而不是绕弯。测试显示，在 Arc Pro B70 上，某些情况下速度提升了 14%。

主要作用 该版本旨在提升 llama.cpp 在 Intel GPU 上的推理性能，特别是针对包含 GLU 操作的模型（如 LLaMA 等），让使用 Intel 显卡的开发者能获得更快的模型运行速度。

核心功能 SYCL 后端 GLU 扁平路径优化：当操作数连续时，使用更快的扁平内核。；合并 fused-GLU 内核：统一不同操作的内核逻辑，减少代码重复。；新增 SWIGLU 性能测试用例：覆盖不同列数、token 数和数据类型，便于性能监控。；移除无用的宏定义：清理代码，简化维护。

对比判断 在 Arc Pro B70 上，split 模式 f16 性能提升 14%，f32 提升 4%，fused 模式无变化。

适合谁 适用于使用 Intel GPU（如 Arc 系列）进行 LLM 推理的开发者，以及关注 llama.cpp 性能优化的研究人员。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10306>

本简报基于 GitHub Release 信息整理，仅供参考。