

重大 AI 更新提醒

08-07 | llama.cpp 修复 NVFP4 量化解析，提升 SYCL GPU 推理正确性

本期导读

本期聚焦 llama.cpp 最新 release b10307，修复了 SYCL GPU 后端对 NVFP4 量化格式中缩放因子的解析错误，确保模型权重正确加载，提升推理准确性。该更新对使用 Intel GPU 的开发者尤为重要。

已检查来源

GitHub Release

1. llama.cpp b10307: 修复 SYCL 后端 NVFP4 量化格式的 UE4M3 解析问题

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 08-07 08:19 | 分数 7

是什么 这是 llama.cpp 项目的一个新版本发布（b10307），主要修复了 SYCL GPU 代码中对于 NVFP4 量化格式的解析错误。具体来说，NVFP4 格式将每 16 个权重共享一个缩放因子，该因子被打包为一个 UE4M3 字节。之前的代码错误地使用了 E4M3 路径（有符号）来转换这些无符号的缩放值，导致权重加载错误。

通俗解释 想象一下，你有一串数字（权重），为了节省空间，每 16 个数字共用一个 缩放因子 来调整大小。这个缩放因子被存储为一种特殊的格式（UE4M3），它表示的是无符号数。但之前的代码误以为它是有符号数（E4M3），就像把温度计上的刻度看反了，导致读出的数值完全错误。这次修复就是纠正了这个误解，让缩放因子能被正确读取，从而保证模型在 GPU 上运行时计算正确。

主要作用 解决 SYCL GPU 后端在加载使用 NVFP4 量化格式的模型时出现的解析错误，确保模型权重正确，避免推理结果出现偏差。对于依赖 Intel GPU 进行推理的开发者，这个修复至关重要。

核心功能 修复 SYCL 后端对 NVFP4 量化格式中 UE4M3 缩放因子的解析；确保无符号缩放值被正确转换，避免权重错误；提供多平台二进制文件，包括 macOS (arm64/x64) 和 iOS XCFramework；Linux Ubuntu x64 CPU 版本同步更新

对比判断 暂无可信公开对比数据

适合谁 适用于使用 llama.cpp 在 SYCL 后端（如 Intel GPU）上运行量化模型的开发者，尤其是使用 NVFP4 量化格式的用户。也适合关注推理基础设施和量化技术的研究者。

直达链接 <https://github.com/qqml-org/llama.cpp/releases/tag/b10307>

本简报基于 GitHub Release 信息，确保内容真实可靠。