

重大 AI 更新提醒

08-10 | vLLM v0.27.0 发布，支持 Kimi K3 等新模型

本期导读

本期聚焦 vLLM 最新版本 v0.27.0，该版本带来多项重大更新，包括对 Kimi K3 的完整支持、多个新模型接入、PyTorch 2.13 升级等，对 AI 推理性能和模型生态有重要影响。

已检查来源

GitHub Release

1. vLLM v0.27.0 发布：支持 Kimi K3、Qwen3.5 等新模型，升级 PyTorch 2.13

来源 GitHub Release | 类型 GitHub Release | 主题 多模态理解 时间 08-10 16:18 | 分数 8

是什么 vLLM 是一个高性能的大语言模型推理和服务引擎，本次 v0.27.0 版本是官方 GitHub 发布的重要更新，包含 561 个提交，来自 242 位贡献者（其中 64 位新贡献者）。该版本重点引入了对 Kimi K3 模型的完整支持，并新增了多个模型架构，同时将 PyTorch 升级到 2.13.0。

通俗解释 想象一下，vLLM 就像一个高效的 AI 模型运行器，它能让大语言模型在服务器上跑得更快、更省内存。这次更新就像给这个运行器换上了新的引擎，并且增加了对几款新车型（模型）的适配。比如，它现在可以完美驱动 Kimi K3 这款新模型，还支持了 Qwen3.5 等。同时，它把底层的 PyTorch 库升级到了 2.13 版本，就像把操作系统升级到最新版，能带来更好的性能和稳定性。

主要作用 该版本旨在提升 vLLM 的模型兼容性和推理性能，使开发者能够更高效地部署和运行最新的开源大模型，尤其是 Kimi K3 这类前沿模型，从而推动 AI 应用的发展。

核心功能 完整支持 Kimi K3：包括核心模型文件、Python 和 Rust 前端、AttnRes 内核、DeepGEMM 支持、压缩张量量化检查点、DSpark AR 融合以及共享专家分片选项。；新增多个模型：Qwen3.5 文本模型（稠密和 MoE）、K-EXAONE-2.0-750B-A37B、VaultGemma（通过 Transformers 后端）、jina-embeddings-v5-text-nano。；PyTorch 2.13.0 升级：同时升级 torchvision 0.28.0 和 Triton 3.7.1，这是一个破坏性环境变更，XPU 和 CPU 也跟进到 torch 2.13。

对比判断 暂无可信公开对比数据。

适合谁 适合使用 vLLM 进行模型推理部署的开发者、AI 工程师和研究团队，尤其是需要支持最新模型（如 Kimi K3）或希望利用 PyTorch 2.13 性能提升的用户。

直达链接 <https://github.com/vllm-project/vllm/releases/tag/v0.27.0>

以上信息基于候选源，请以官方发布为准。