

重大 AI 更新提醒

08-12 | llama.cpp 新增 Pocket-TTS 支持，推理性能大幅提升

本期导读

本期聚焦 llama.cpp 最新版本 b10369，该版本引入了对 Pocket-TTS 的支持，并优化了转置卷积实现，显著提升了生成速度。对于在本地部署 TTS 模型的开发者，这是一个重要更新。

已检查来源

GitHub Release

1. llama.cpp b10369: 支持 Pocket-TTS，生成速度提升 80%

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 08-11 23:52 | 分数 8

是什么 这是 llama.cpp 的一个新版本（b10369），主要增加了对 Pocket-TTS 模型的支持，并重构了转置卷积的实现方式，以提升解码速度。

通俗解释 Pocket-TTS 是一个文本转语音模型，llama.cpp 是一个让 AI 模型在普通电脑上运行的软件。这次更新让 llama.cpp 能运行 Pocket-TTS，并且通过优化底层数学运算，让语音生成速度大幅提升。比如，以前生成一帧语音需要 1 秒，现在可能只需要 0.2 秒，就像把慢速的火车换成了高铁。

主要作用 解决在本地高效运行 TTS 模型的问题，让开发者无需高端 GPU 也能快速生成语音，适合边缘计算或实时应用。

核心功能 支持 Pocket-TTS 模型，扩展了 llama.cpp 的多模态能力；优化转置卷积：将深度卷积转换为 GEMM + col2im，减少计算节点；生成时间每帧降低 80%（CUDA）和 50%（CPU）；保持输出与之前一致，不影响模型精度

对比判断 根据发布说明，生成时间每帧在 CUDA 上降低 80%，在 CPU 上降低 50%。

适合谁 适合需要在本地或边缘设备部署 TTS 的开发者，尤其是使用 llama.cpp 进行多模态推理的团队。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10369>

本简报基于公开信息整理，请以官方发布为准。