

重大 AI 更新提醒

08-17 | llama.cpp 重大性能修复：SYCL 量化拷贝内核提速

本期导读

本期聚焦 llama.cpp 最新 release b10456，针对 SYCL 后端的量化拷贝内核进行了关键修复，显著提升了特定路径的吞吐量，对 Intel GPU 用户尤为重要。

已检查来源

GitHub Release

1. llama.cpp b10456: SYCL 量化拷贝内核线程 块计数修复，q4_0 到 f32 路径吞吐提升 7.8 倍

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 08-17 01:29 | 分数 9

是什么 这是 llama.cpp 项目的一个新 release (b10456)，主要修复了 SYCL 后端中量化拷贝 (quantized cpy) 内核启动时的线程 块计数问题。该修复调整了线程 块的数量，使其与量化数据的大小成比例，从而减少过度订阅或订阅不足的情况。

通俗解释 想象一下，你有一个工厂流水线，每个工人负责处理一定数量的零件。如果工人太多而零件太少，工人就会闲着；如果工人太少而零件太多，就会堆积。这个修复就是让工人数量 (线程 块) 和零件数量 (量化数据大小) 匹配起来，这样效率就高了。具体到技术场景，在 Intel 显卡 (如 Arc 70) 上，将模型从 q4_0 量化格式转换为 f32 格式时，速度从 20.21 GB/s 提升到了 158.19 GB/s，快了约 7.8 倍。

主要作用 这个修复解决了 SYCL 后端在量化拷贝操作中的性能瓶颈，特别是对于需要频繁进行量化格式转换的场景 (如推理时的中间计算)，能显著提升整体推理速度，降低延迟，改善用户体验。

核心功能 修复了 SYCL 量化拷贝内核的线程 块计数逻辑，使其与量化大小成比例；针对 q4_0 到 f32 路径实现了最大性能提升，吞吐量从 20.21 GB/s 提升至 158.19 GB/s；其他量化类型的性能也有小幅提升，整体更稳定；提供了 macOS、iOS、Linux 等多个平台的预编译二进制文件

对比判断 根据 release 说明，在 Arc 70 上，q4_0 到 f32 路径的吞吐量从 20.21 GB/s 提升到 158.19 GB/s，提升约 7.8 倍；其他量化类型性能持平。

适合谁 适用于使用 llama.cpp 在 Intel GPU (如 Arc 系列) 上进行推理的开发者，特别是需要处理量化模型转换的场景，以及关注 SYCL 后端性能优化的研究人员。

直达链接 <https://github.com/qgml-org/llama.cpp/releases/tag/b10456>

本简报基于 GitHub Release 信息，数据截至 2026-08-17。