

重大 AI 更新提醒

08-17 | llama.cpp 发布 b10472，修复 AMD APU 显存检测问题

本期导读

本期聚焦 llama.cpp 的最新版本发布，该版本针对 AMD APU 的显存报告进行了修复，提升了在小型显存配置下的内存管理准确性。对于使用 AMD 平台的开发者，这是一个重要的稳定性更新。

已检查来源

GitHub Release

1. llama.cpp b10472 发布：修复 AMD APU 显存报告，提升内存管理准确性

来源 GitHub Release | 类型 GitHub Release | 主题 检索增强与向量模型 | 时间 08-17 12:16 | 分数 7

是什么 这是 llama.cpp 的一个新版本发布（b10472），主要修复了在 HIP 构建中跳过 UMA 覆盖的问题，使得 AMD APU 能够通过 hipMemGetInfo 报告准确的内存信息。

通俗解释 想象一下，你的电脑内存就像一个仓库，而显存是仓库里专门放货物的一小块区域。以前，对于 AMD 的 APU（一种把 CPU 和 GPU 集成在一起的芯片），llama.cpp 可能会错误地认为整个仓库都可以用来放货物，导致在货物太多时出现空间不足的问题。这次更新让程序更准确地知道实际可用的显存大小，避免过度承诺，就像仓库管理员终于知道真正的可用空间，不会再把货物堆到过道上了。

主要作用 解决在小型显存配置下，llama.cpp 因使用 MemAvailable 而高估可用显存的问题，避免内存溢出或性能下降，提升在 AMD APU 设备上运行大型语言模型的稳定性。

核心功能 跳过 UMA 覆盖：在 HIP 构建中不再强制使用统一内存架构的覆盖设置，而是依赖硬件实际报告。；使用 hipMemGetInfo：改用更准确的内存查询接口，获取真实可用显存。；修复 issue #18159：解决了特定场景下的内存报告不准确问题。

对比判断 暂无可信公开对比数据

适合谁 适合使用 AMD APU 或 AMD GPU 的开发者，特别是那些在小型显存设备上运行 llama.cpp 的用户，以及关注内存优化的研究人员。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10472>

本简报基于候选源生成，所有信息均来自原始发布。