

重大 AI 更新提醒

08-23 | Ray 2.58.0 发布，KV 缓存与 token 感知路由正式完成

本期导读

本期聚焦 Ray 2.58.0 的发布，该版本完成了 KV 缓存与 token 感知请求路由，显著提升 LLM 推理效率。适合关注分布式计算和 LLM 推理优化的开发者。

已检查来源

GitHub Release

1. Ray 2.58.0 发布：Ray Serve LLM 完成 KV 缓存与 token 感知路由

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 08-23 00:42 | 分数 8

是什么	Ray 2.58.0 是 Ray 分布式计算框架的一个版本更新，重点改进了 Ray Serve LLM 组件，实现了 KV 缓存和 token 感知的请求路由，该功能在 2.57 中预览，现已正式完成。
通俗解释	想象一个繁忙的图书馆，每个读者（请求）都需要借书（模型推理）。以前，每次借书都要重新查找（重新计算），现在图书馆有了一个智能索引（KV 缓存），能记住读者上次借的位置，直接带他们去拿书，省时省力。Ray 2.58.0 就是给 AI 推理加了这个智能索引，让模型不用重复计算，还能根据请求的 token 数量智能分配任务，提高效率。
主要作用	解决 LLM 推理中重复计算和路由效率低下的问题，通过 KV 缓存和 token 感知路由，减少 token 重复处理，提升推理吞吐和响应速度，降低延迟。
核心功能	KV 缓存与 token 感知路由：在 LLMRouter 入口副本内进行 tokenization，路由决策基于 token 信息，token 带外传输，避免引擎重复 tokenize。；KV 生命周期事件广播：KV 缓存的生命周期事件广播到所有入口副本，确保缓存一致性。；CPU KV 缓存感知：路由时考虑 CPU KV 缓存，使 offloaded KV 缓存块计入缓存命中，提高缓存利用率。；任务事件卸载：支持将任务事件从聚合器导出到 dashboard head，通过内存存储供状态 API 和 ray.timeline 读取。
对比判断	暂无可信公开对比数据
适合谁	适合使用 Ray 进行分布式计算、特别是部署 LLM 服务的开发者和团队，以及关注推理性能优化的研究人员。

直达链接 <https://github.com/ray-project/ray/releases/tag/ray-2.58.0>

本简报基于候选源生成，确保信息真实可靠。