

重大 AI 更新提醒

08-25 | llama.cpp 0.3.0 发布，支持多模态与张量并行

本期导读

本期聚焦 llama.cpp 0.3.0 版本更新，该版本引入 dots3-note 多模态模型、GLM-4.5-Air 的 MTP 支持，以及 DeepSeek 4 的张量拆分模式，显著提升推理灵活性与性能。

已检查来源

GitHub Release

1. llama.cpp v0.3.0 发布：新增 dots3-note 多模态模型、GLM-4.5-Air MTP 支持及 DeepSeek 4 张量拆分

来源 GitHub Release | 类型 GitHub Release | 主题 多模态理解 时间 08-25 05:22 | 分数 8

是什么 这是 llama.cpp 项目的 0.3.0 版本正式发布。llama.cpp 是一个流行的开源 C/C++ 推理引擎，用于在本地运行大语言模型。本次更新引入了新的多模态模型 dots3-note，支持 GLM-4.5-Air 的多 token 预测（MTP），并为 DeepSeek 4 增加了张量拆分模式，同时升级了底层 ggml 库到 v0.22.0，并改进了服务器和 Web UI。

通俗解释 想象一下，你有一个工具箱，里面有很多工具。llama.cpp 就是这样一个工具箱，它让你能在自己的电脑上运行 AI 模型。这次更新，工具箱里加了几件新工具：一是 dots3-note，它能同时理解文字、图片和声音，就像一个人既能看又能听；二是对 GLM-4.5-Air 的支持，让这个模型能一次预测多个 token，就像打字时一次打出几个词，速度更快；三是 DeepSeek 4 的张量拆分，可以把模型分成几块，放在多个 GPU 上运行，就像把一个大拼图分给几个人一起拼，效率更高。

主要作用 这次更新主要解决三个问题：一是扩展 llama.cpp 对多模态模型的支持，让用户能在本地处理图像、音频和文本的混合任务；二是提升特定模型的推理速度，通过 MTP 技术减少生成时间；三是优化多 GPU 环境下的资源利用，通过张量拆分让大型模型（如 DeepSeek 4）能在多卡上高效运行。对于开发者来说，这意味着更丰富的模型选择和更灵活的部署方式。

核心功能 新增 dots3-note 多模态模型，支持视觉和音频输入，并引入新的 DSA-ISWA KV cache 类型，优化缓存效率。；为 GLM-4.5-Air 添加 MTP（Multi-Token Prediction）支持，可同时预测多个 token，加速生成。；DeepSeek 4 支持张量拆分模式（sm tensor），允许将模型分布到多个 GPU 上，并修复了多序列回滚问题。；ggml 升级至 v0.22.0，包含元后端张量拆分、逐操作 Metal 内核并行编译等底层优化。

对比判断 暂无可信公开对比数据。

适合谁 适合需要在本地或私有环境部署大模型的开发者、研究者和企业团队，尤其是关注多模态推理、多 GPU 并行加速或希望使用最新模型（如 GLM-4.5-Air、DeepSeek 4）的用户。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/v0.3.0>

以上信息基于候选源，请以官方发布为准。