

重大 AI 更新提醒

08-25 | OpenAI 发布自研推理芯片 Jalapeño，性能与效率领先

本期导读

本期聚焦 OpenAI 官方发布的定制推理芯片 Jalapeño 的首批结果，该芯片在推理速度、吞吐量和能效方面表现出行业领先水平，对 AI 基础设施和模型部署具有重大意义。

已检查来源

OpenAI 官方新闻

1. Jalapeño 首批结果：AI 推理速度与效率行业领先

来源 OpenAI 官方新闻 类型 官方发布 主题 推理性能与基础设施 时间 08-25 02:00 | 分数 7

是什么 Jalapeño 是 OpenAI 自研的定制推理芯片，专为加速现代 AI 模型的推理过程而设计。该芯片在吞吐量和延迟方面表现优异，同时显著提升能效，是 OpenAI 在硬件基础设施领域的重要布局。

通俗解释 想象一下，AI 模型就像一个超级大脑，但思考需要消耗大量电力和时间。Jalapeño 芯片就像是给这个大脑装上了涡轮增压器，让它想得更快、更省电。比如，以前处理一张图片可能需要几秒，现在可能只需零点几秒，而且电费还更少。这对于使用 AI 服务的用户来说，意味着更快的响应和更低的成本。

主要作用 解决 AI 推理过程中的性能瓶颈和能耗问题，为大规模部署现代模型提供更高效、更经济的基础设施支持，同时减少对第三方芯片的依赖，增强 OpenAI 的技术自主性。

核心功能 高吞吐量：支持并发处理大量推理请求，适合高负载场景。；低延迟：显著缩短模型响应时间，提升用户体验。；高能效：在相同功耗下提供更高计算性能，降低运营成本。；针对现代模型优化：专为当前主流架构设计，发挥最佳性能。

对比判断 暂无可信公开对比数据

适合谁 适合 AI 基础设施团队、模型部署工程师、云计算提供商以及需要大规模推理服务的开发者，尤其关注推理成本和速度的企业。

直达链接 <https://openai.com/index/jalapeno-first-results>

以上信息基于 OpenAI 官方发布，更多细节请访问原文链接。