

重大 AI 更新提醒

08-26 | Qwen4-Exp 发布与 llama.cpp CUDA 优化

本期导读

今日 Hugging Face Transformers 发布 v5.16.0，正式支持 Qwen4-Exp 混合架构模型；llama.cpp 发布 b10635，针对旧款 NVIDIA GPU 优化 MoE 推理性能。

已检查来源

GitHub Release

1. Hugging Face Transformers v5.16.0 发布，新增 Qwen4-Exp 模型支持

来源 GitHub Release | 类型 GitHub Release | 主题 多模态理解 | 时间 08-26 07:35 | 分数 8

是什么 Hugging Face Transformers 库的 v5.16.0 版本正式发布，主要新增了对 Qwen4-Exp 模型的支持。Qwen4-Exp 是 Qwen 系列的最新实验性模型，基于 Qwen3.5 的混合文本与多模态架构，引入了 GatedResidual (GR)、Qwen Sparse Attention (QSA) 和 Per-Layer Embedding (PLE) 三个核心组件。

通俗解释 想象一下，一个模型既要处理文字又要处理图片，就像一个人既要看书又要看画。Qwen4-Exp 通过三种新技术来提升这种多模态处理能力：GatedResidual 像是一个智能开关，控制信息在神经网络各层之间的流动；Qwen Sparse Attention 则像是一个高效的阅读器，只关注文本中最相关的部分，而不是逐字逐句地读，从而加快处理速度；Per-Layer Embedding 则让每一层都能更好地理解输入内容。这些技术让模型在处理长文档或复杂图像时更快、更准确。

主要作用 为开发者提供对最新 Qwen4-Exp 模型的开箱即用支持，方便在 Transformers 生态中直接加载、微调 and 部署该模型，推动多模态 AI 应用的发展。

核心功能 GatedResidual (GR)：结合 Hyper-Connection 与 GatedNorm，通过细粒度门控混合多个残差流，控制信息注入。；Qwen Sparse Attention (QSA)：使用多个查询头对压缩键块进行评分，选择最相关的连续 token 块，降低索引开销并提升长序列的内存局部性。；Per-Layer Embedding (PLE)：每层独立嵌入，增强模型对输入的代表能力。；混合架构：结合 Gated DeltaNet，成为首个集成线性注意力的混合架构。

对比判断 暂无可信公开对比数据

适合谁 适合使用 Transformers 库进行多模态模型开发的研究人员、AI 工程师，以及需要处理长文本和图像任务的团队。

直达链接 <https://github.com/huggingface/transformers/releases/tag/v5.16.0>

2. llama.cpp b10635 发布：为旧款 NVIDIA GPU 解锁 MoE 量化推理

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 08-26 06:32 | 分数 7

是什么	llama.cpp 发布了 b10635 版本，主要针对 CUDA 后端进行了优化，特别是为 sm_60 架构（如 Pascal 系列）的 GPU 解锁了 MoE（Mixture of Experts）模型的 mmq（多矩阵量化）支持，并调整了非 dp4a 的 Pascal GPU 上的占用率。
通俗解释	MoE 模型就像是一个由多个专家组成的团队，每次只调用部分专家，从而节省计算资源。但旧款 GPU（比如 GTX 10 系列）之前无法高效运行这种模型。这次更新相当于给这些旧 GPU 打开了新的大门，让它们也能运行 MoE 模型，并且通过调整占用率，让量化后的模型运行得更流畅。
主要作用	提升 llama.cpp 在旧款 NVIDIA GPU 上的推理性能，扩大 MoE 模型的硬件兼容性，让更多用户能在低端设备上运行大型语言模型。
核心功能	为 sm_60 架构解锁 mmq 支持，使 MoE 模型在 Pascal GPU 上可用。；为 dp4a 和更旧的 GPU 复制 mmq 配置，确保兼容性。；调整非 dp4a Pascal GPU 的占用率，优化 Q2_K、Q4_K、Q5_K、Q6_K 等量化级别的性能。
对比判断	暂无可信公开对比数据
适合谁	适合使用旧款 NVIDIA GPU（如 GTX 10 系列）进行本地推理的开发者、AI 爱好者，以及需要低成本部署 LLM 的团队。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10635>

以上信息基于 GitHub Release 官方发布，请以原始链接为准。