

重大 AI 更新提醒

08-27 | llama.cpp 新增 DFlash2 支持，加速本地推理

本期导读

本期聚焦 llama.cpp 最新版本 b10658，该版本引入了对 DFlash2 的支持，通过局部卷积和候选选择器优化了推理过程，为本地大模型推理带来性能提升。

已检查来源

GitHub Release

1. ggml-org/llama.cpp release b10658: 新增 DFlash2 支持（局部卷积 候选选择器）

来源 GitHub Release | 类型 GitHub Release | 主题 检索增强与向量模型 | 时间 08-27 13:32 | 分数 7

是什么 这是 llama.cpp 的一个新版本发布，llama.cpp 是一个流行的 C/C++ 实现的 LLM 推理引擎，支持在本地运行多种大语言模型。本次更新主要增加了对 DFlash2 的支持，DFlash2 是一种推测解码（speculative decoding）技术，通过局部卷积和候选选择器来加速生成。

通俗解释 想象一下，你在写文章时，通常一个字一个字地敲，但如果你能预测下一个词，就可以一次敲好几个词。DFlash2 就是帮助模型预测多个词的技术，它使用一个小的辅助模型（候选选择器）来生成候选词，然后用主模型验证。局部卷积则帮助辅助模型更好地理解上下文。这样，主模型可以一次处理多个词，从而加快生成速度。对于普通用户来说，这意味着在本地运行大模型时，响应更快，体验更流畅。

主要作用 该更新旨在提升 llama.cpp 的推理性能，特别是通过推测解码减少生成延迟，让本地部署的大模型运行更高效，降低计算成本，同时保持生成质量。

核心功能 支持 DFlash2 推测解码，结合局部卷积和候选选择器；引入 p_min 参数，优化候选选择过程；重构代码结构，优化 DFlash2 成本；修复 mrope bug，确保兼容性

对比判断 暂无可信公开对比数据

适合谁 适合使用 llama.cpp 进行本地推理的开发者、研究人员，以及需要优化大模型推理性能的团队。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10658>

本简报基于候选源生成，请以官方发布为准。