

重大 AI 更新提醒

08-28 | llama.cpp 发布 SYCL 优化，KV Cache 内存带宽大幅降低

本期导读

本期聚焦 llama.cpp 最新 release b10669，该版本针对 SYCL 路径优化了 f16 KV Cache 的绑定，显著减少了 prefill 阶段的内存流量，尤其对长上下文场景提升明显。适合使用 Intel GPU 或 oneDNN 后端的开发者关注。

已检查来源

GitHub Release

1. llama.cpp release b10669: SYCL 路径绑定 f16 KV Cache，降低 oneDNN SDPA 内存流量

来源 GitHub Release | 类型 GitHub Release | 主题 开发者生态与数据工具 时间 08-28 07:44 | 分数 7

是什么	这是 llama.cpp 的一个新版本（b10669），主要针对 SYCL（Intel 的异构计算平台）后端，在 oneDNN 的 SDPA（Scaled Dot-Product Attention）路径中，将 f16 类型的 KV Cache 直接绑定到计算图中，以减少数据拷贝和内存传输。
通俗解释	想象一下，你在处理很长的文本（比如 32768 个 token），模型需要记住之前所有的内容（KV Cache）。在旧版本中，每次计算注意力时，都需要把 KV Cache 数据从内存搬到计算单元，就像每次都要把书从书架上拿下来再放回去，很费时间。这个更新让 KV Cache 直接放在计算单元旁边，省去了搬运过程，从而加快了处理速度，尤其对于长文本和 Intel GPU 用户。
主要作用	解决长上下文场景下 prefill 阶段内存带宽瓶颈，提升推理速度，降低延迟，特别针对 Intel GPU 和 oneDNN 后端。
核心功能	SYCL 后端支持 f16 KV Cache 的就地绑定；优化 oneDNN SDPA 路径的内存访问模式；减少每个 ubatch 的内存流量（从 4.56 GB 降至 0.27 GB，取决于序列长度）；提供调试命令（GGML_SCHED_DEBUG）用于复现和验证
对比判断	在 Qwen3.8 27B Q4_K_S 模型上，当 KV 长度为 34816 时，每个 ubatch 的内存流量从 4.56 GB 降至 0.27 GB（序列长度为 2048 时），但这是同一版本在不同序列长度下的对比，并非与旧版本对比。暂无可信公开对比数据。
适合谁	适合使用 Intel GPU（如 Arc、Xe 系列）的开发者，或使用 SYCL/oneDNN 后端的 llama.cpp 用户，尤其是需要处理长上下文（如 32K+）的推理服务部署者。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10669>

以上信息基于候选源，请以官方发布为准。