

重大 AI 更新提醒

08-29 | llama.cpp 优化 Adreno GPU 推理性能

本期导读

本期聚焦 llama.cpp 最新 release b10687，针对 Adreno GPU 优化矩阵乘法路径，显著提升 gpt-oss-20b 等模型的 prefill 速度。该更新对移动端和边缘设备上的大模型推理具有重要意义。

已检查来源

GitHub Release

1. llama.cpp b10687: 优化 Adreno GPU 矩阵乘法路径，提升 gpt-oss-20b 推理性能

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 08-29 13:23 | 分数 7

是什么	这是 llama.cpp 项目的一个新版本发布（b10687），主要针对 Adreno GPU（特别是 X2-90 和 Adreno 840）优化了矩阵乘法（matmul）的实现路径。具体来说，它默认启用了 Adreno X2E 上的 xmem F16xF32 GEMM 内核，替换了之前较慢的 kernel_mul_mm_f16_f32_l4_lm，从而提升了特定模型的 prefill 速度。
通俗解释	想象一下，GPU 就像一条高速公路，矩阵乘法是运输数据的卡车。之前，在 Adreno GPU 上，某些卡车（内核）走了一条很慢的路线，导致数据传输效率低下。这次更新，llama.cpp 为 Adreno X2-90 等 GPU 选择了一条更快的路线（xmem GEMM），让数据运输更快。具体来说，对于 gpt-oss-20b 这样的模型，prefill（处理输入文本的阶段）速度提升了约 25%。这就像把高速公路上的慢车道改成了快车道，让车辆跑得更快。
主要作用	解决 Adreno GPU 上特定矩阵乘法内核性能低下的问题，特别是针对 gpt-oss-20b 这类模型，其非专家权重保持 f16 精度，导致 prefill 阶段大量时间消耗在慢速内核上。通过默认启用更快的 xmem 路径，显著提升推理速度，改善用户体验，并降低延迟。
核心功能	默认启用 Adreno X2E 上的 xmem F16xF32 GEMM 内核，替代慢速的 kernel_mul_mm_f16_f32_l4_lm；针对 Adreno X2-90 优化，gpt-oss-20b 的 prefill 速度提升约 25%；对 Adreno 840 保持中性，不影响其性能；通过环境变量可控制该优化，且仅在 N 16 时生效，不影响 decode 阶段
对比判断	在 Adreno X2-90 上，gpt-oss-20b 的 prefill 速度提升约 25%，而 Adreno 840 上性能中性。此外，该优化对 q8attn 变体无影响，因为其注意力权重已使用 dp4a 密集 GEMM。
适合谁	适用于使用 Adreno GPU（特别是 X2-90 和 Adreno 840）的开发者、研究人员和团队，尤其是那些在移动设备或边缘设备上部署大模型（如 gpt-oss-20b）并关注推理性能的用户。

直达链接 <https://github.com/qgml-org/llama.cpp/releases/tag/b10687>

本简报基于 GitHub Release 信息整理，仅供参考。