

重大 AI 更新提醒

08-30 | llama.cpp 发布 HIP 优化，提升 AMD GPU 推理性能

本期导读

本期聚焦 llama.cpp 最新版本 b10702，该版本针对 AMD RDNA 3.5 架构（gfx1201）优化了 Q2_0 量化模型的点积计算路径，显著提升推理速度。适合使用 AMD GPU 运行本地大模型的开发者关注。

已检查来源

GitHub Release

1. llama.cpp b10702: 针对 AMD gfx1201 优化 Q2_0 点积路径，提升推理性能

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 08-30 16:20 | 分数 7

是什么 这是 llama.cpp 项目的一个新版本发布（b10702），主要针对 AMD 的 gfx1201 架构（即 RDNA 3.5 系列 GPU）优化了 Q2_0 量化格式的点积计算路径。具体包括使用原生的 amdgc n perm 指令来加速向量点积，并优化了 MMQ（矩阵乘法量化）的解包过程。

通俗解释 想象一下，你有一个巨大的乐高模型（大语言模型），为了让它能放进小盒子（内存），你需要把乐高块压缩（量化）。Q2_0 是一种压缩方式，它把每个乐高块的信息用很少的比特表示，但计算时还需要把这些压缩块重新展开来拼装。这个版本就像是为 AMD 的特定型号 GPU 专门设计了一套更快的拼装工具，让展开和计算更快。具体来说，它利用了 AMD GPU 的硬件指令（amdgc n perm）来直接处理压缩数据，减少了中间步骤，从而让模型运行得更快。

主要作用 解决 AMD GPU 上运行量化模型时计算效率低的问题，特别是针对最新的 RDNA 3.5 架构。通过优化底层计算路径，提升推理速度，降低延迟，让使用 AMD 显卡的开发者能更流畅地运行本地大模型。

核心功能 针对 gfx1201 架构优化 Q2_0 点积路径，使用原生 amdgc n perm 指令；优化 HIP 的 Q2_0 解包（MMQ）过程，减少冗余操作；清理了 HIP 预处理器守卫，并恢复了 MMQ 的 tile 索引处理

对比判断 暂无可信公开对比数据

适合谁 适合使用 AMD RDNA 3.5 系列 GPU（如 RX 9000 系列）的开发者，尤其是那些在本地运行 llama.cpp 并采用 Q2_0 量化模型的用户。也适合对底层推理优化感兴趣的工程师。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10702>

本简报基于候选源自动生成，请以官方发布为准。