

重大 AI 更新提醒

08-31 | llama.cpp Vulkan 推理性能优化

本期导读

本期聚焦 llama.cpp 最新版本 b10714，针对 Vulkan 后端在 RDNA3 和 Strix Halo 平台上的矩阵 向量乘法进行了调优，显著提升了批处理推理性能。该更新对使用 AMD GPU 的开发者尤为重要。

已检查来源

GitHub Release

1. llama.cpp b10714: Vulkan 后端针对 RDNA3 和 Strix Halo 优化矩阵 向量乘法，提升批处理推理性能

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 08-31 04:40 | 分数 7

是什么 这是 llama.cpp 的一个新版本（b10714），主要针对 Vulkan 后端进行了性能调优。具体来说，它调整了矩阵 向量乘法（mat-vec）的行数设置，以更好地适应 AMD RDNA3 架构和 Strix Halo 平台。

通俗解释 想象一下，你在用 AMD 显卡运行 AI 模型，比如让 AI 写文章或回答问题。这个过程需要大量的数学计算，其中一种关键计算叫 矩阵 向量乘法。llama.cpp 是一个帮助在普通电脑上运行 AI 模型的软件，它利用显卡加速计算。这次更新就像是为 AMD 显卡量身定制了一套更高效的 计算配方，让显卡在处理这类计算时速度更快，尤其是在同时处理多个任务（批处理）时。例如，在 Strix Halo 设备上，通过固定使用 4 行设置，比默认设置更快，就像在高速公路上为特定车型开辟了专用车道，减少了拥堵。

主要作用 解决 AMD GPU（特别是 RDNA3 架构和 Strix Halo 平台）上运行 llama.cpp 时推理性能不佳的问题，通过优化 Vulkan 后端的矩阵 向量乘法实现，提升批处理推理速度，让用户获得更流畅的 AI 体验。

核心功能 针对 RDNA3 架构，在列数超过四列时，静态使用 4 行进行矩阵 向量乘法，比默认设置更快。；针对 Strix Halo 平台，在 mul_mat_vec_id 操作中，静态使用 4 行，在不同类型和批处理大小下均优于默认设置。；提供了 macOS Apple Silicon (arm64) 和 Intel (x64) 的预编译二进制文件，方便用户直接使用。

对比判断 暂无可信公开对比数据。但根据提交信息，在 Strix Halo 机器上，静态 4 行设置比默认设置更快，覆盖多种类型和批处理大小。

适合谁 适合使用 AMD RDNA3 或 Strix Halo 显卡的开发者、研究人员和 AI 爱好者，尤其是那些通过 llama.cpp 在本地运行大语言模型并追求更高推理速度的用户。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10714>

本简报基于 GitHub Release 信息，确保内容真实可靠。